Series de Tiempo I

Modelos para Tendencia y Suavización

Profesor : Duván Humberto Cataño Salazar

E-Mail : duvan.catano@udea.edu.co

Universidad de Antioquia
Facultad de Ciencias Exactas y Naturales
Instituto de Matemáticas

2026 - 2



Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Definición

Serie de Tiempo

Es una secuencia $\{x_t\}_{t=1}^{T}$, de observaciones (datos), ordenadas y equidistantes temporalmente sobre una característica (univariada) o sobre varias características (multivariada) de una unidad observable en diferentes momentos.

UNIVERSIDAD DE ANTIOQUIA
1803

Serie de Tiempo

Es una secuencia $\{x_t\}_{t=1}^{T}$, de observaciones (datos), ordenadas y equidistantes temporalmente sobre una característica (univariada) o sobre varias características (multivariada) de una unidad observable en diferentes momentos.

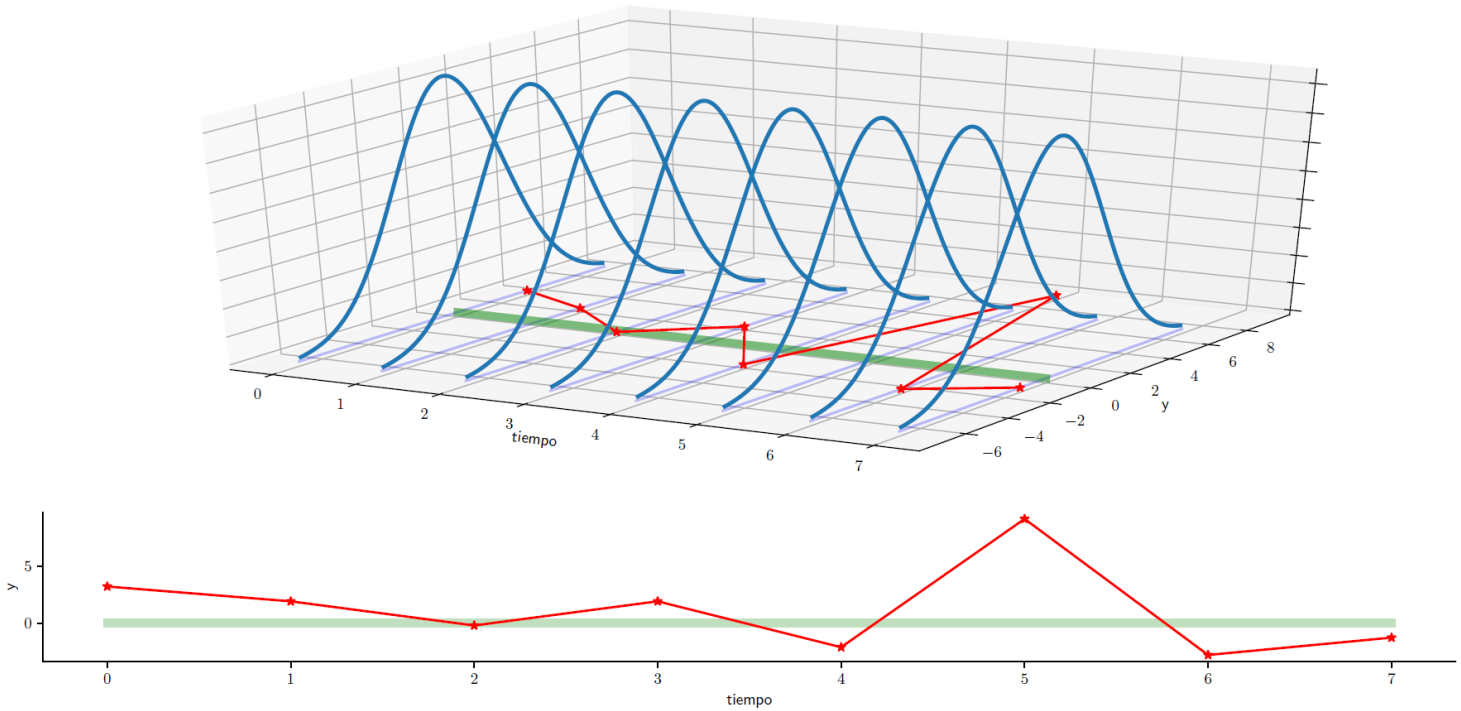


Figura: Proceso Estocástico & Serie de Tiempo

Ganancias trimestrales por acción, 84 trimestres, 1960-I a 1980-IV.

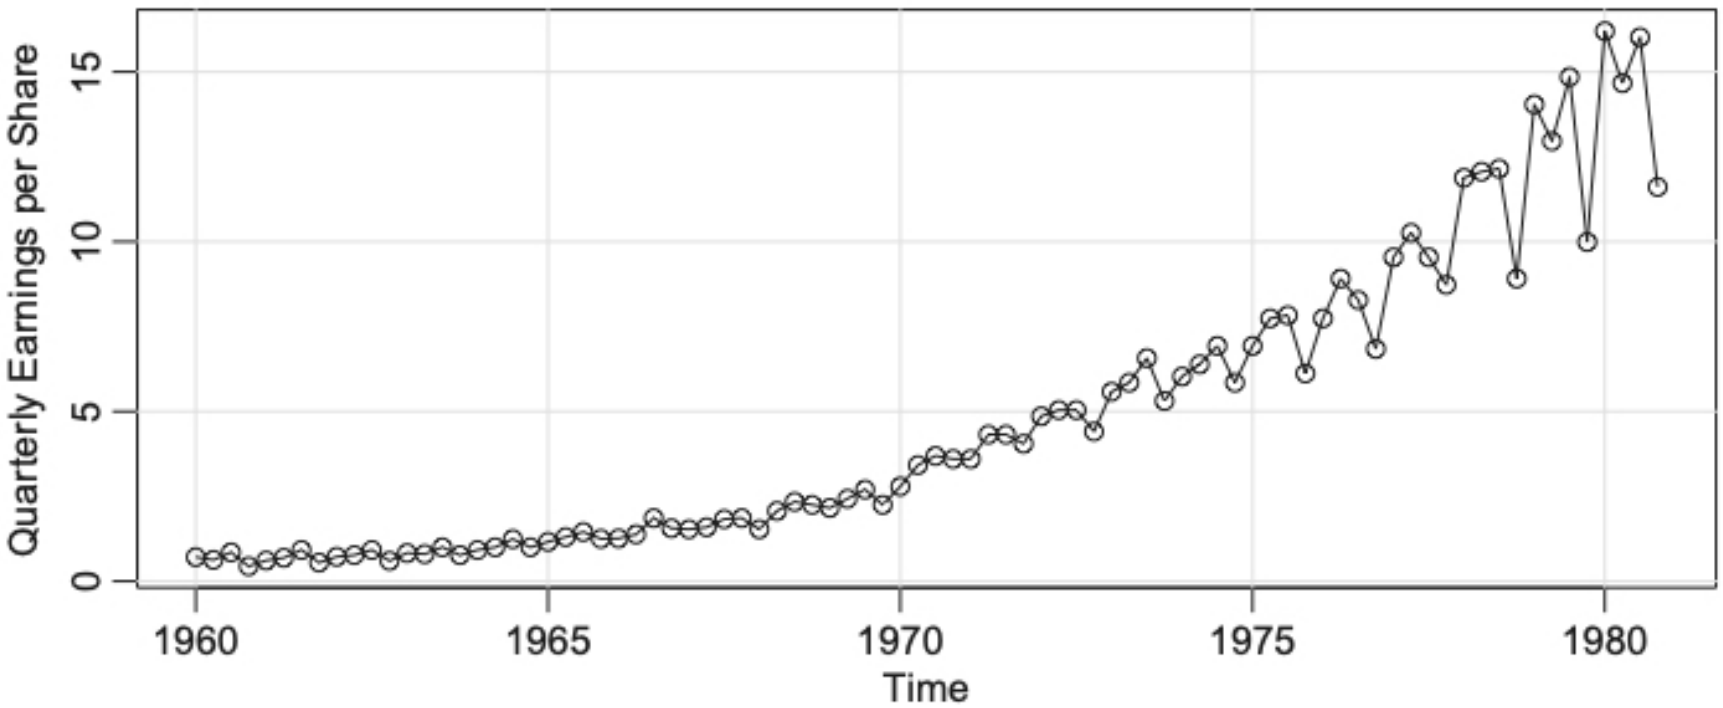


Figura: Ganacias Trimestrales

UNIVERSIDAD DE ANTIOQUIA
1803

Desviaciones medias anuales de la temperatura global (1880-2015) en °C.

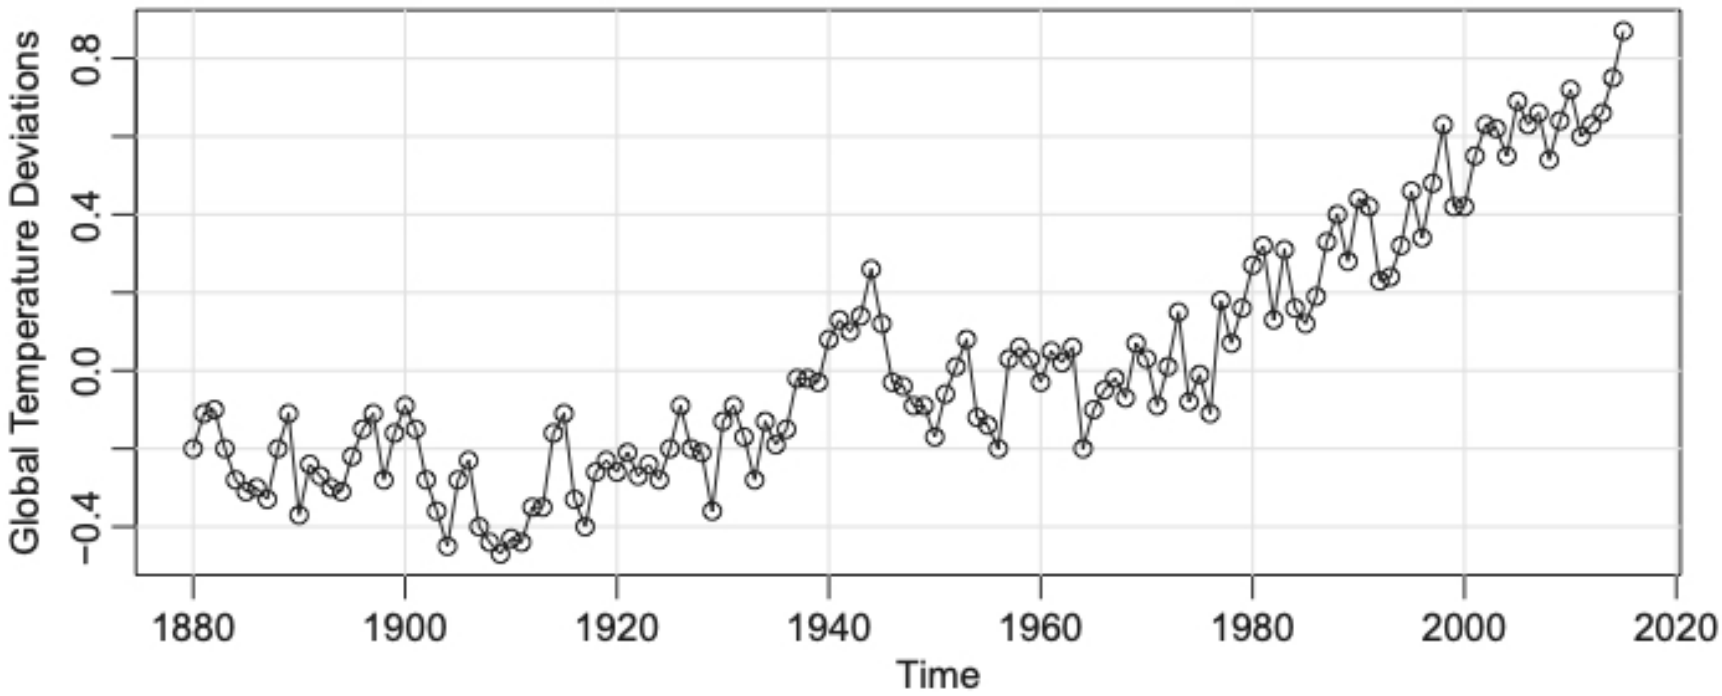


Figura: Desviaciones medias

UNIVERSIDAD DE ANTIOQUIA
1803

Los rendimientos diarios del Dow Jones Industrial Average (DJIA) del 20 de abril de 2006 al 20 de abril de 2016.

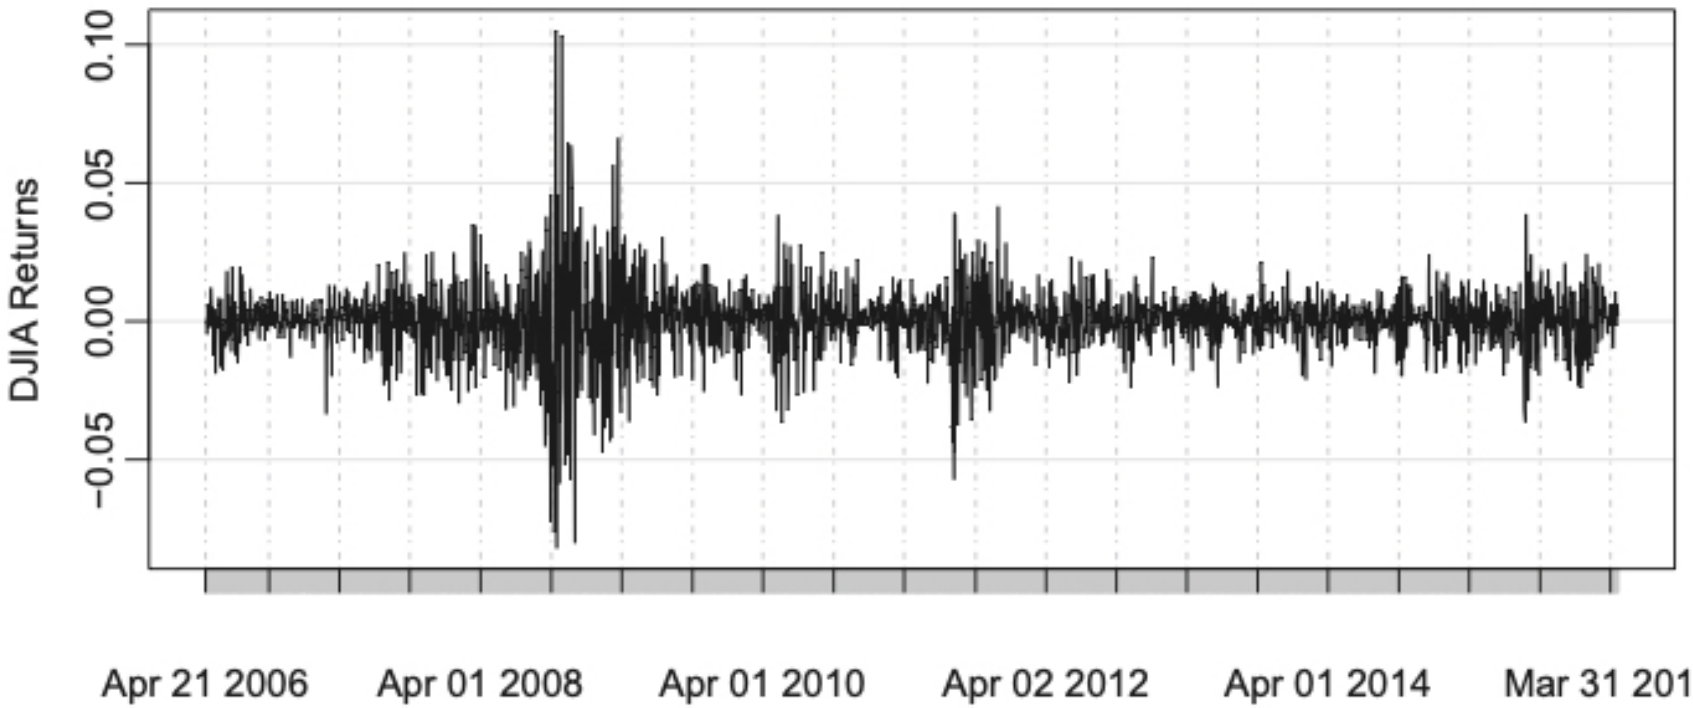


Figura: Rendimientos Diarios del Dow Jones

UNIVERSIDAD DE ANTIOQUIA
1803

Datos de resonancia magnética funcional de diversas ubicaciones de la corteza, el tálamo y el cerebelo; $n = 128$ puntos, una observación tomada cada $2seg$.

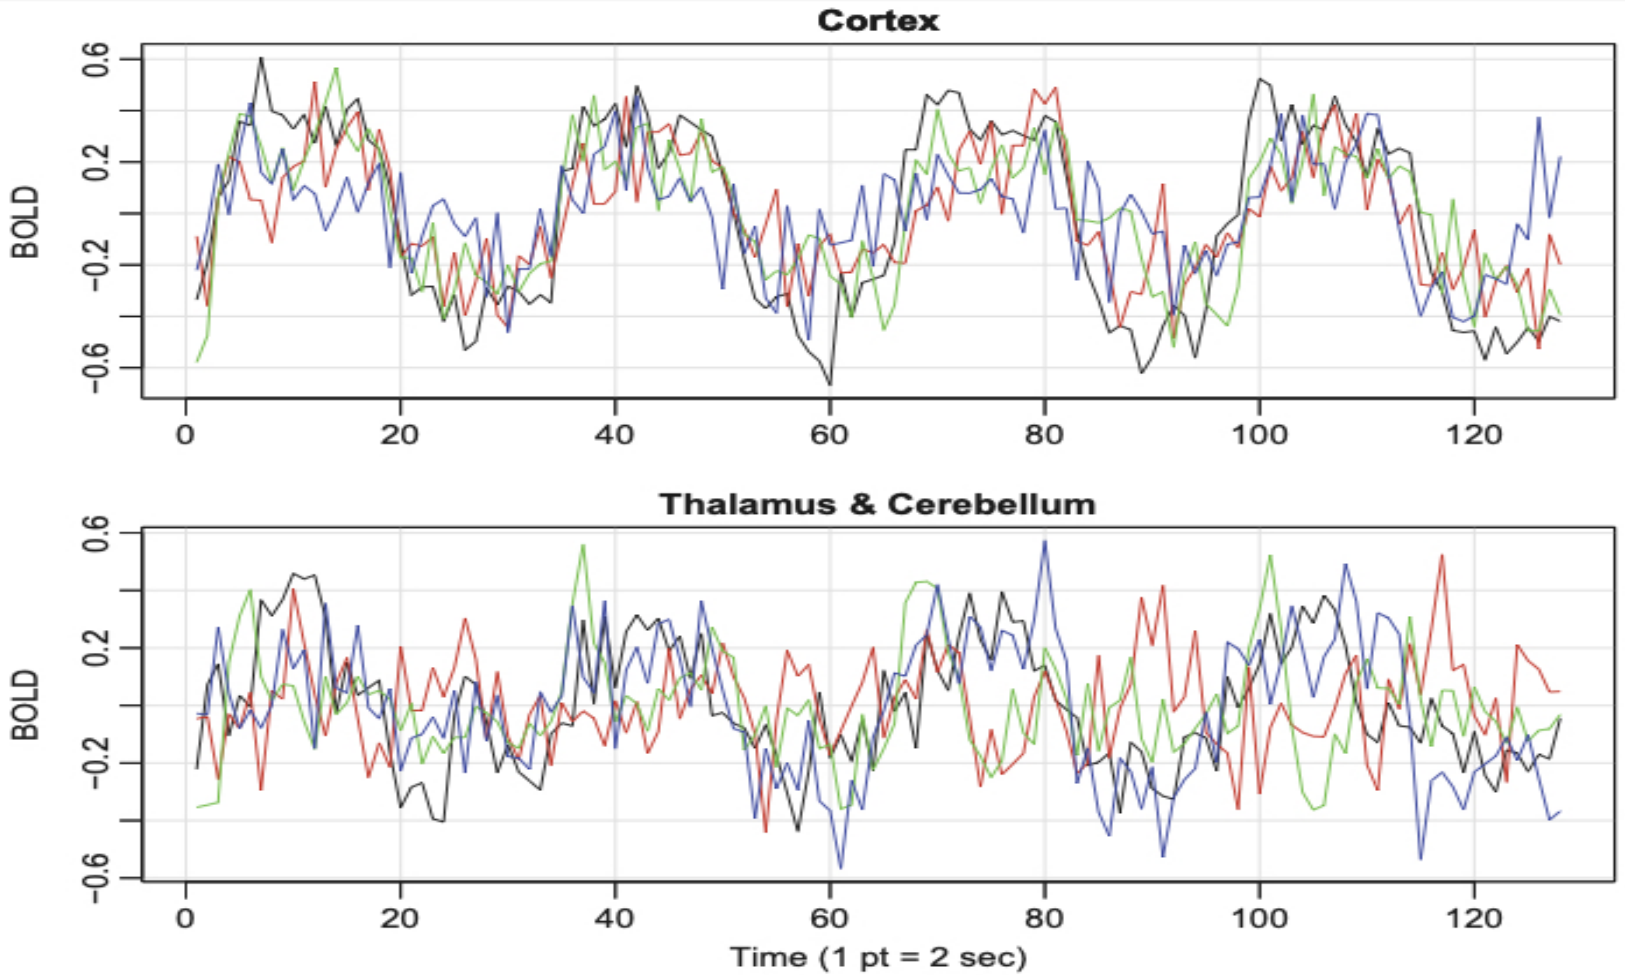


Figura: Señal BOLD

UNIVERSIDAD DE ANTIOQUIA
1803

Fases de llegada de un terremoto (arriba) y una explosión (abajo), 40 *puntos/seg*.

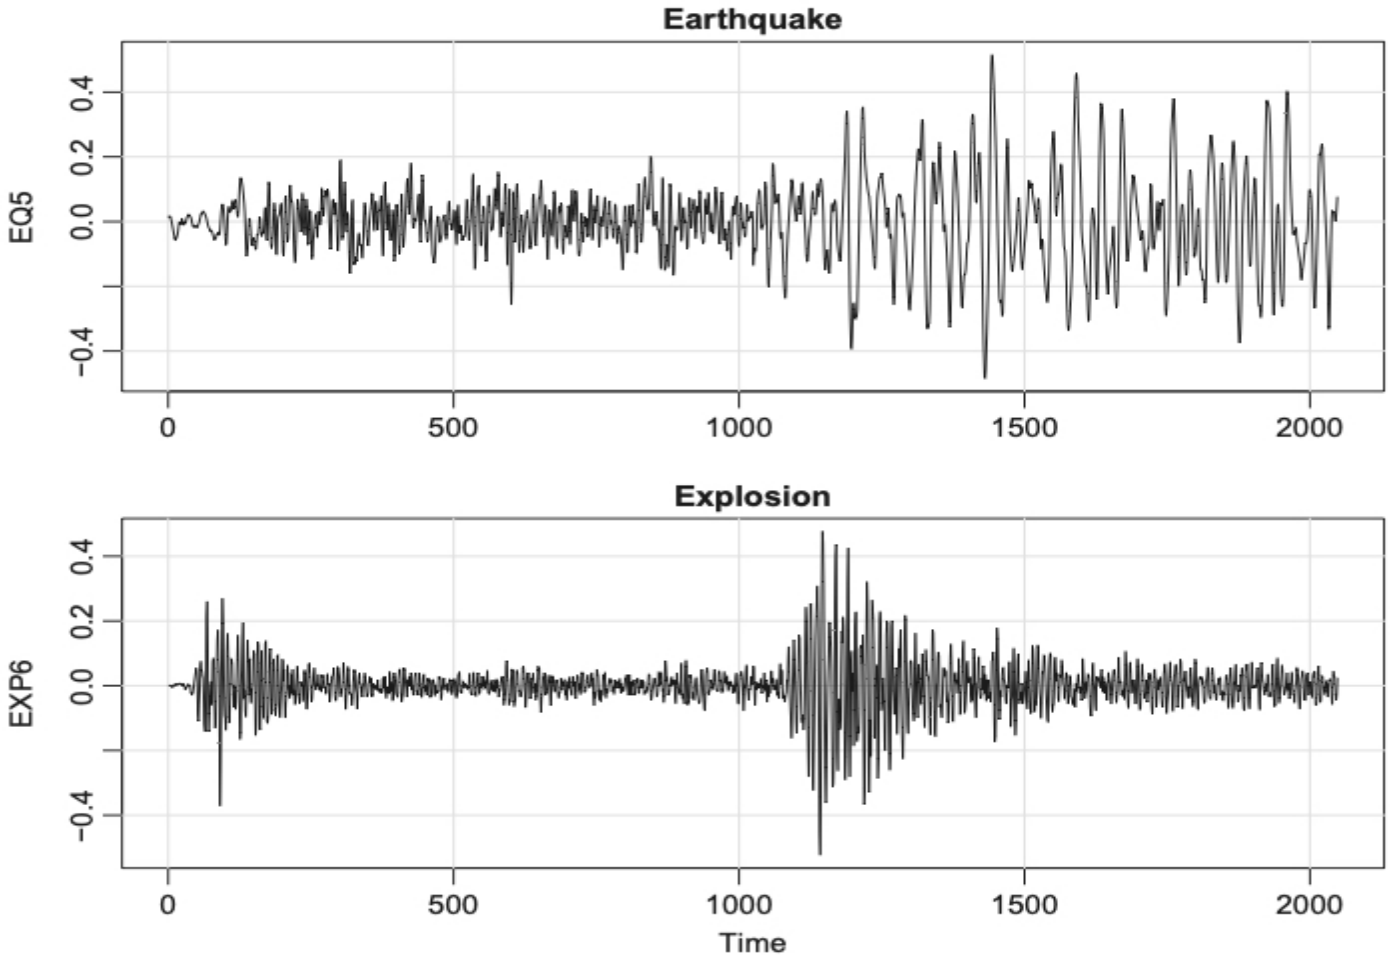


Figura: Intensidades

UNIVERSIDAD DE ANTIOQUIA
1803

Descomposición de una serie para analizar sus periodicidades.

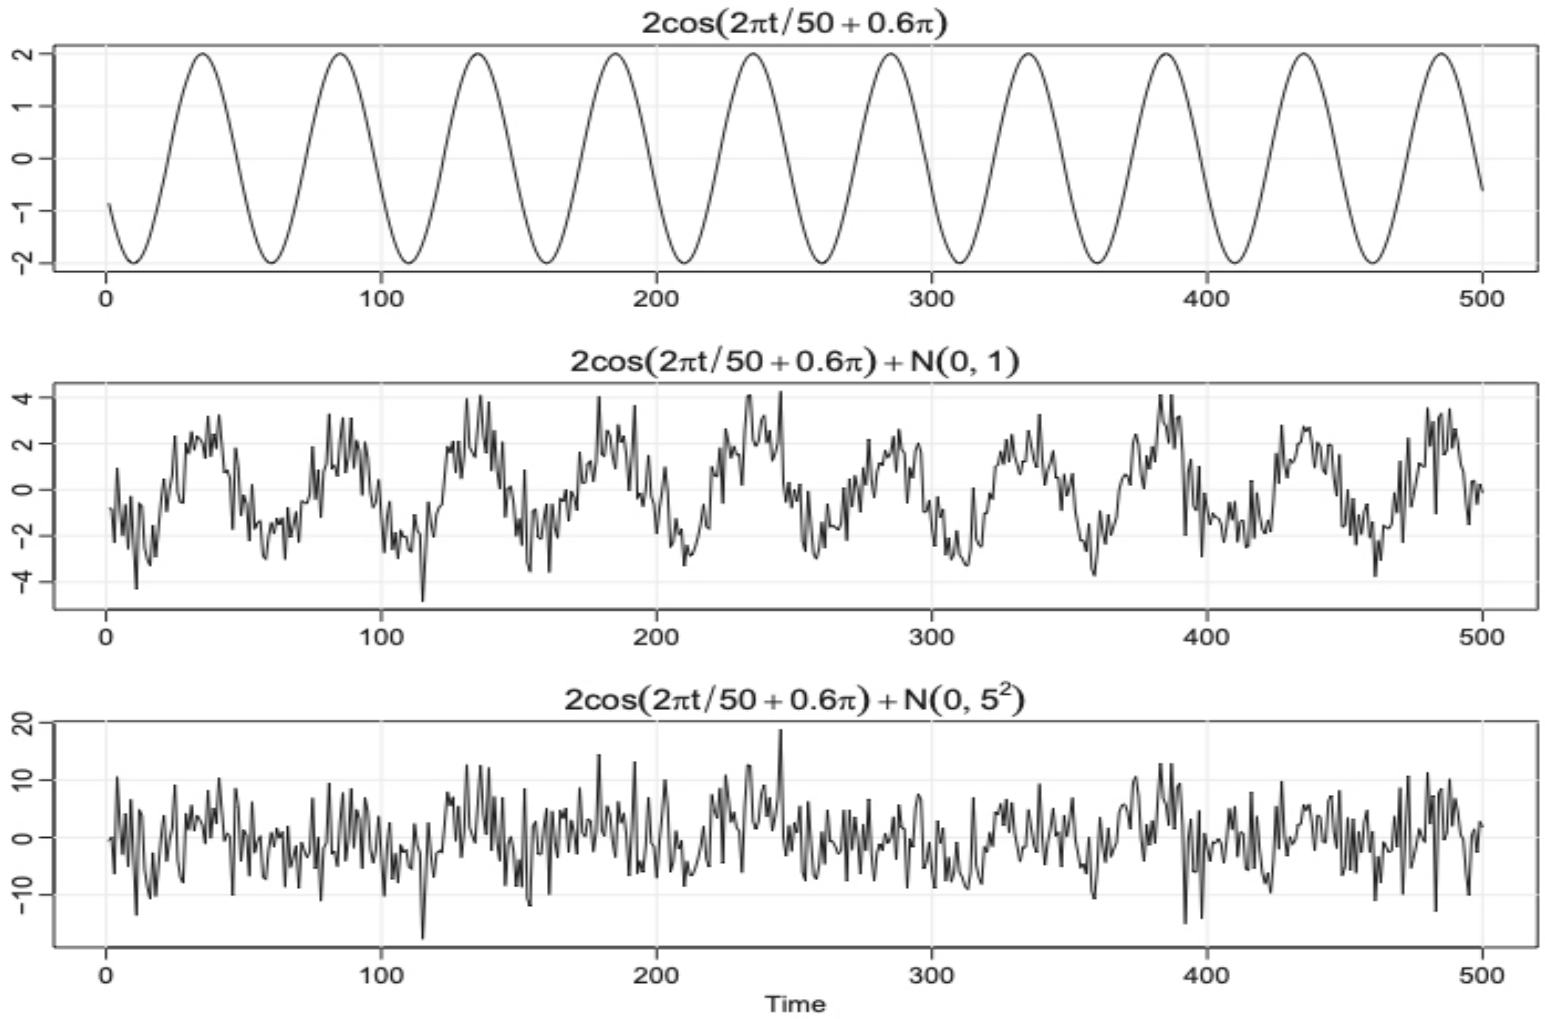


Figura: Descomposición

Espesores de varvas glaciales (arriba) de Massachusetts durante $n = 634$ años en comparación con espesores con transformación logarítmica (abajo).

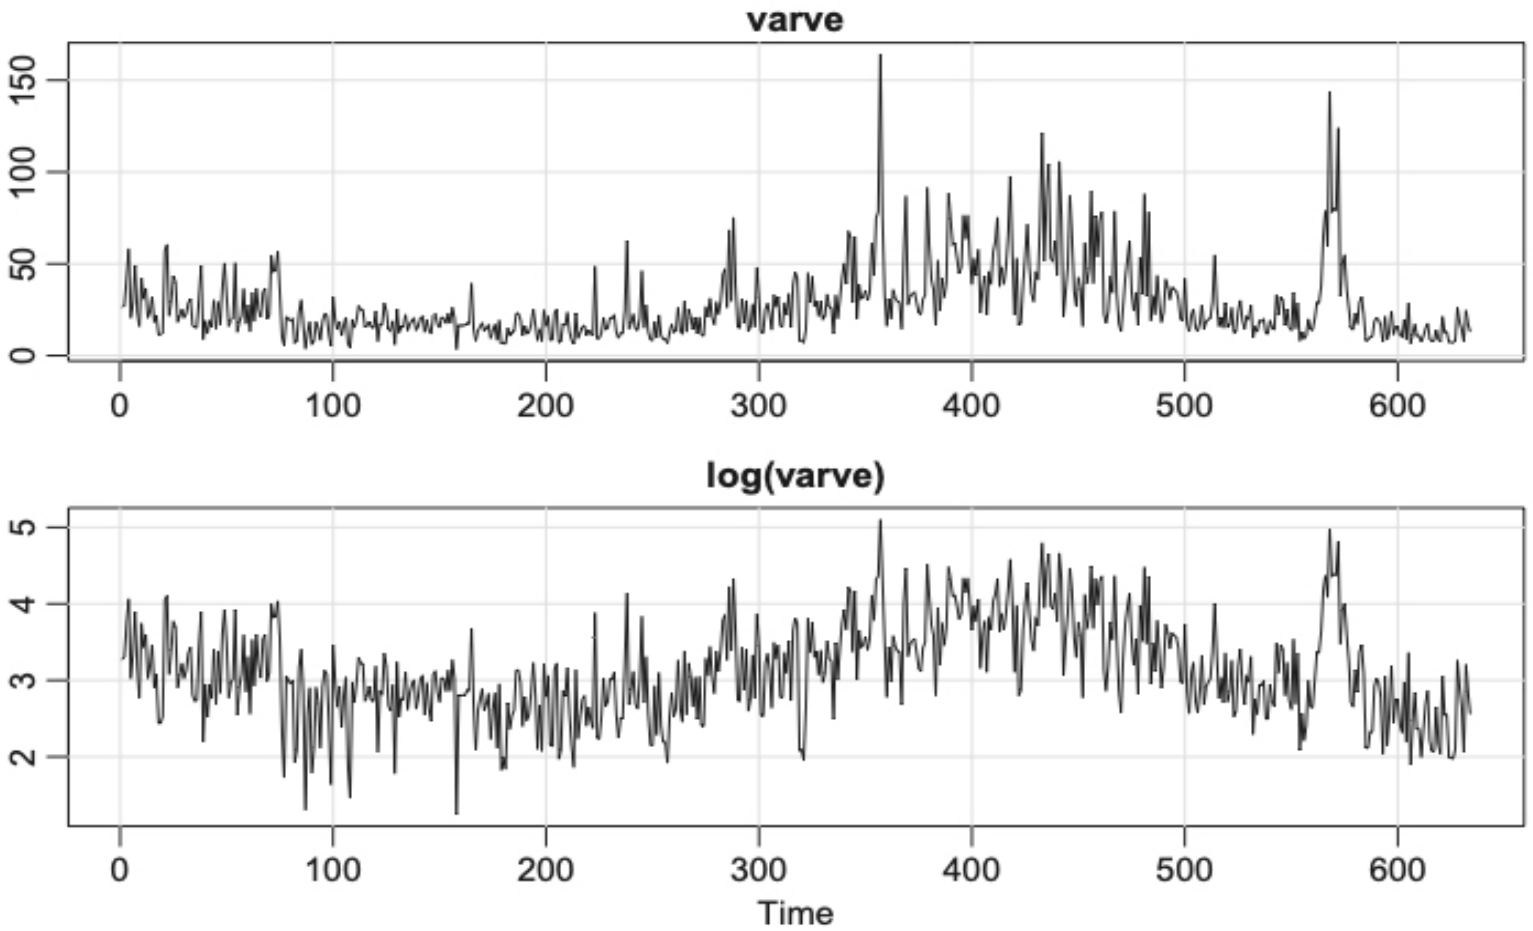


Figura: Transformación

Pronósticos a veinticuatro meses de la serie Contratación. Los datos reales que se muestran son aproximadamente desde enero de 1980 hasta septiembre de 1987, y luego se muestran los pronósticos más y menos un error estándar.

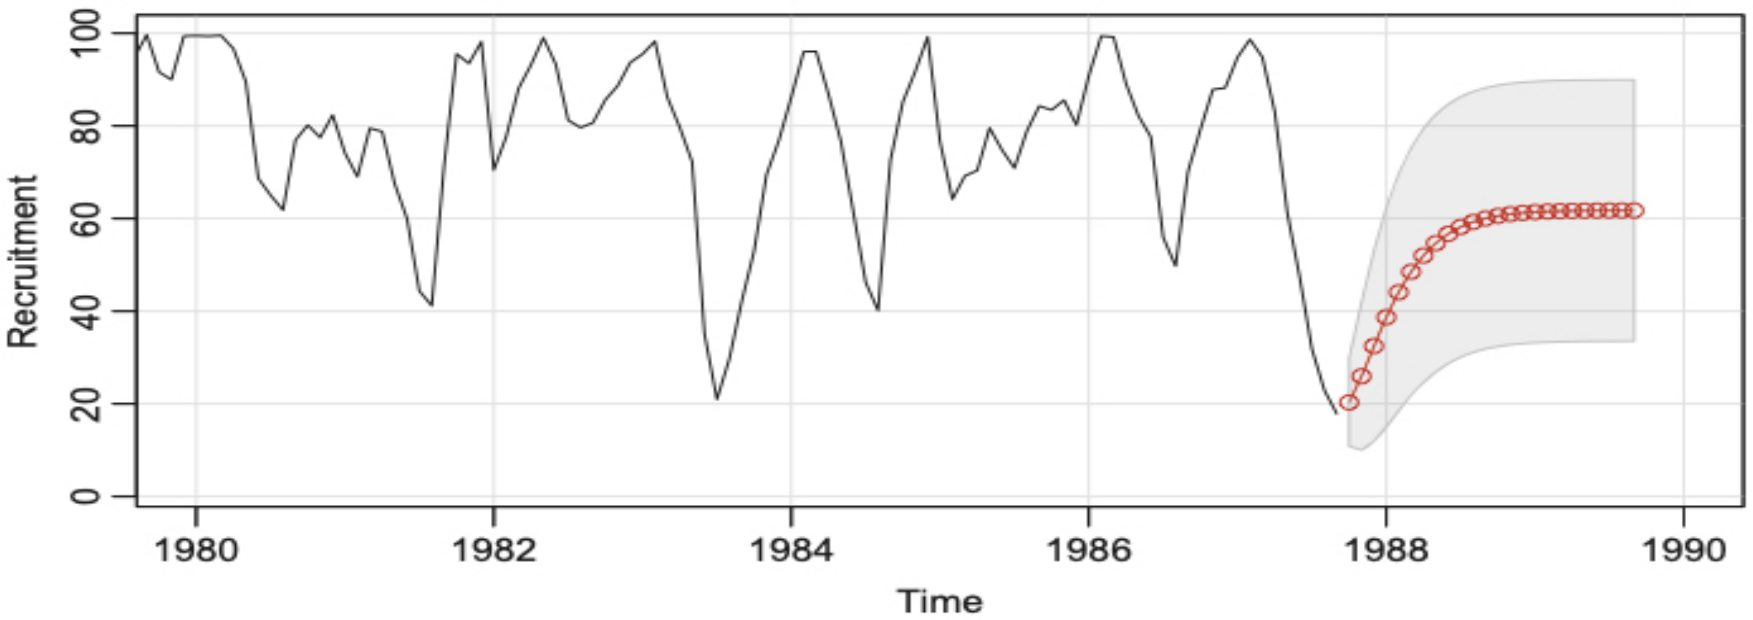


Figura: Pronósticos

Datos de un Electroencefalograma antes, durante y después de un ataque de epilepsia.

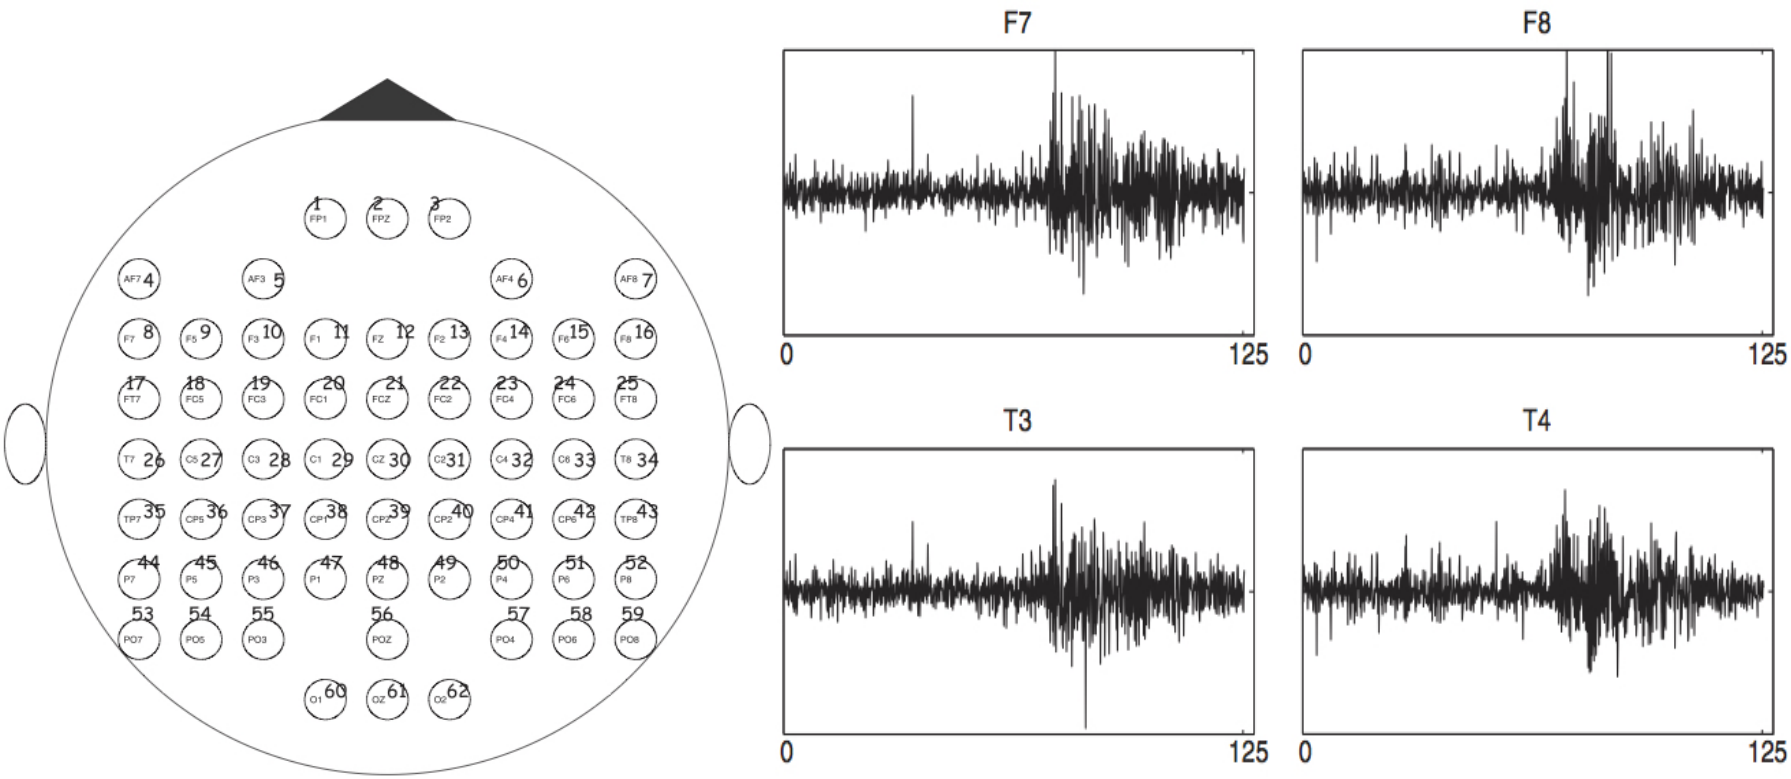


Figura: Datos EEG

Comovimientos de Temperatura y Humedad en bosque de Palma de Aceite.

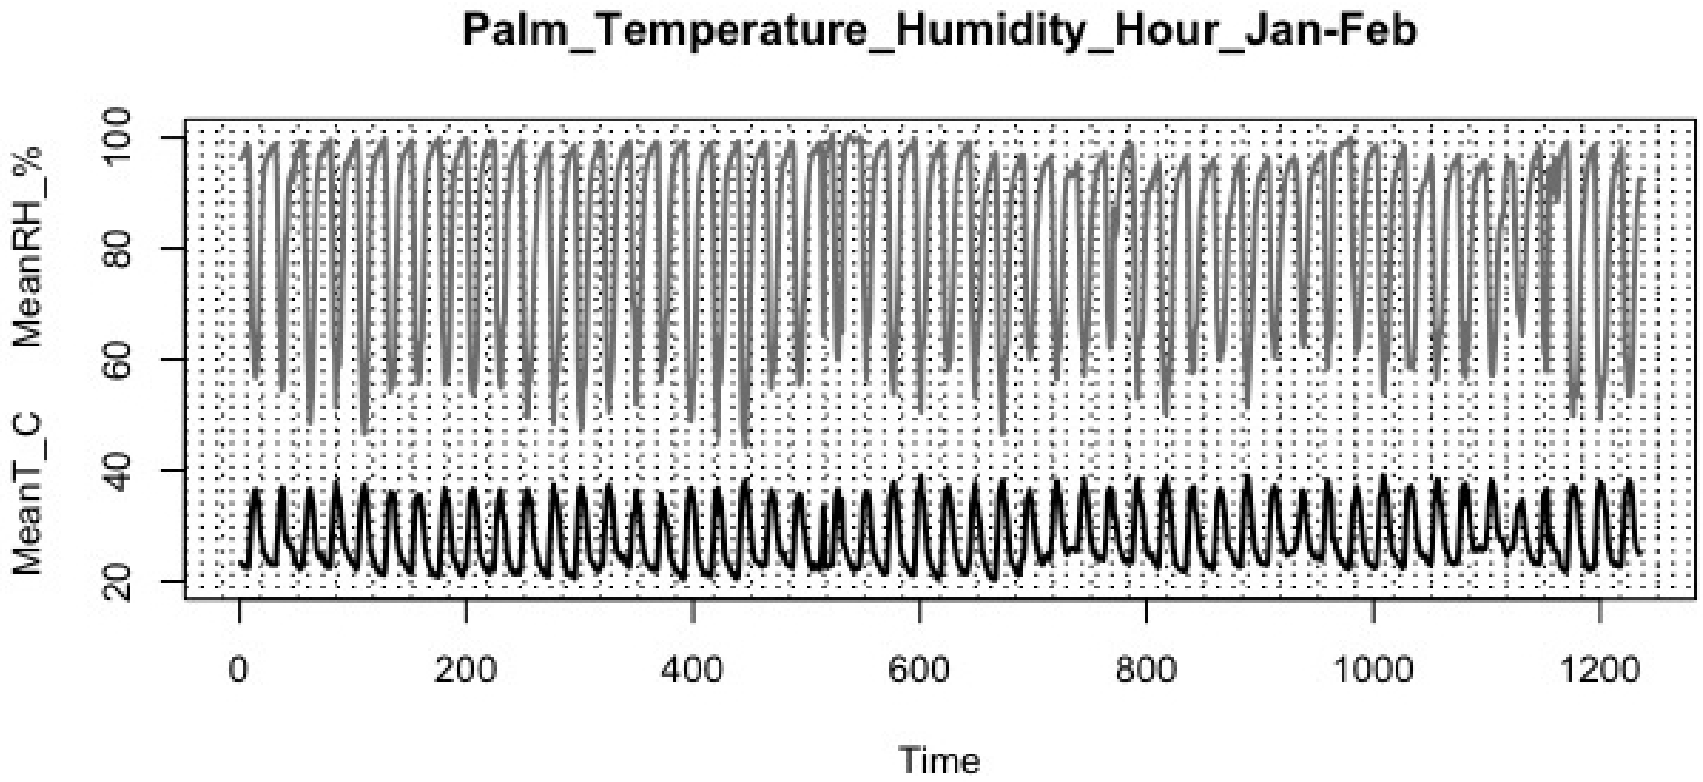


Figura: Relaciones de Movimientos

UNIVERSIDAD DE ANTIOQUIA
1803

Comovimientos de Pastura y Humedad en bosque de Palma de Aceite.

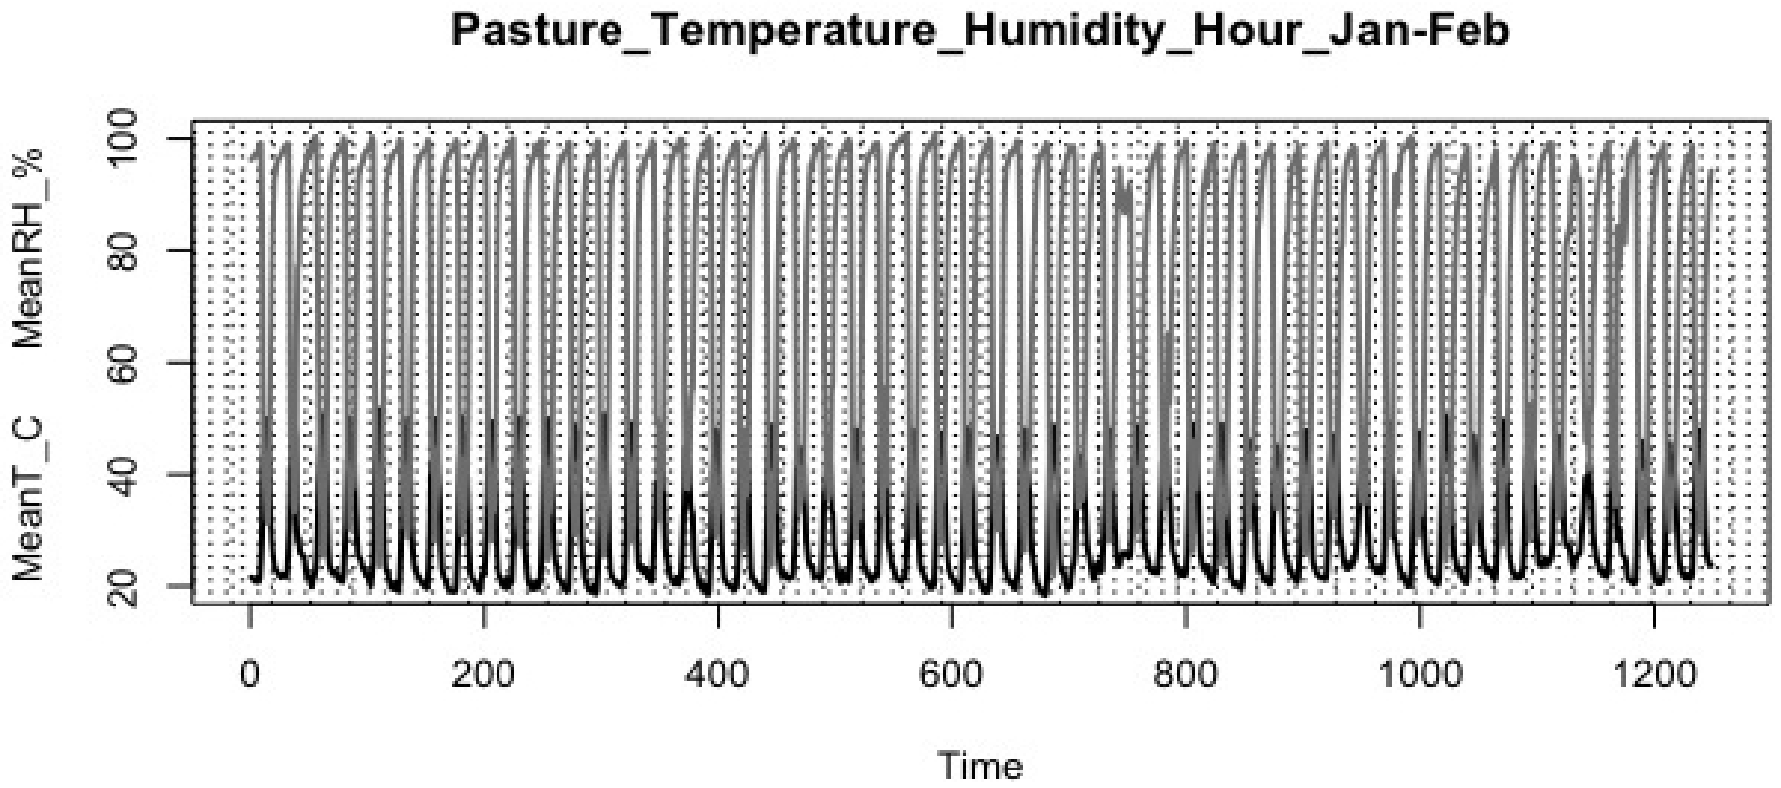


Figura: Relaciones de Movimientos

UNIVERSIDAD DE ANTIOQUIA
1803

Número de reclamos en Bancolombia por usuarios de Canales Digitales.

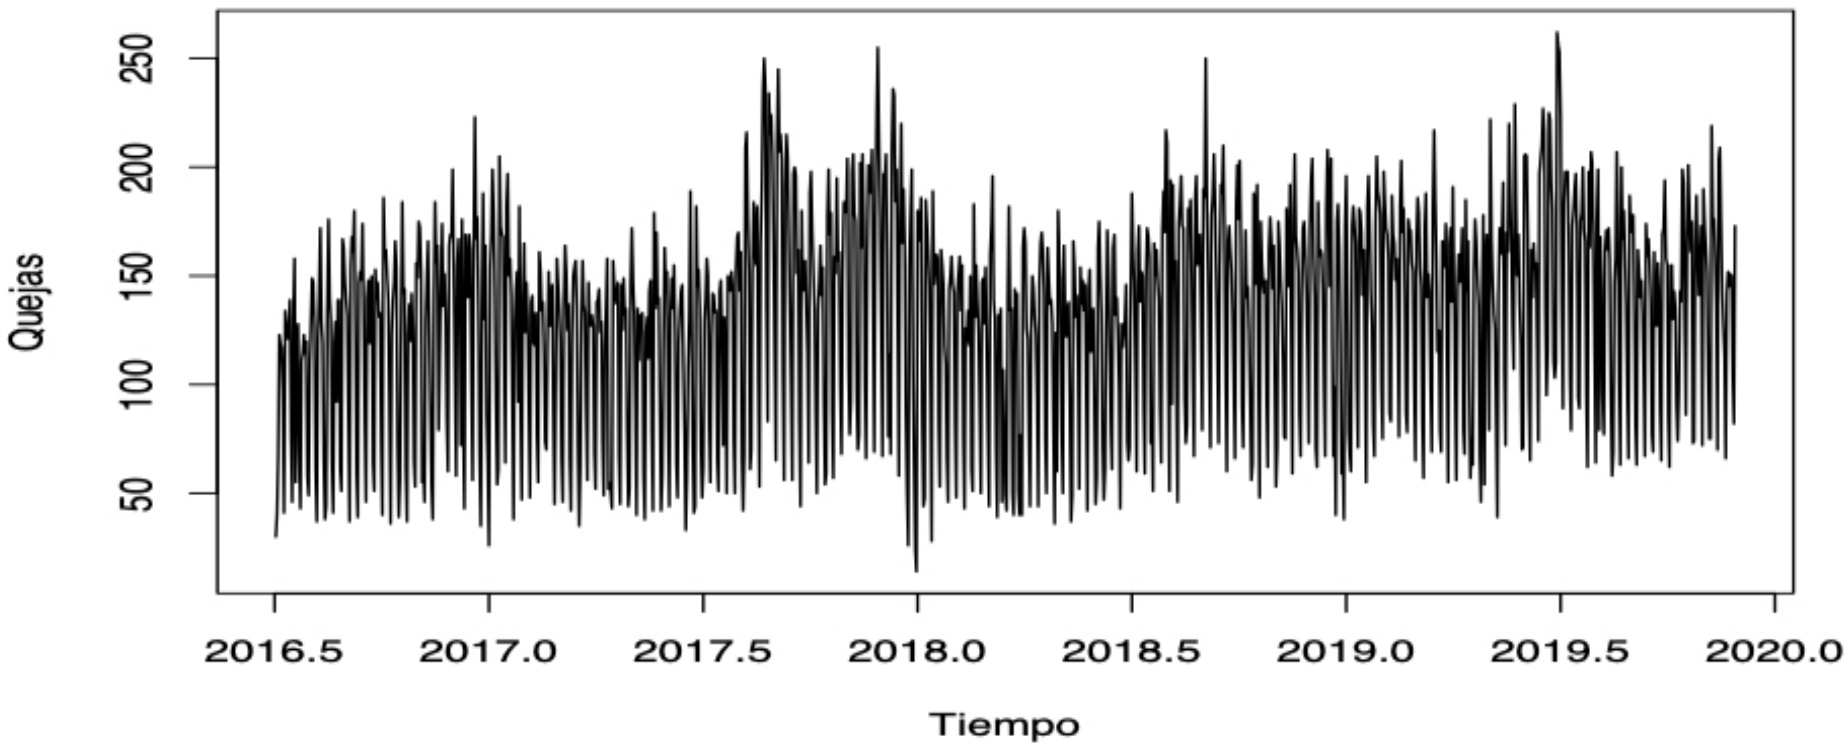


Figura: Conteo de Reclamos

UNIVERSIDAD DE ANTIOQUIA
1803

Tasa de interés (negro) y su volatilidad variando en el tiempo (rojo).

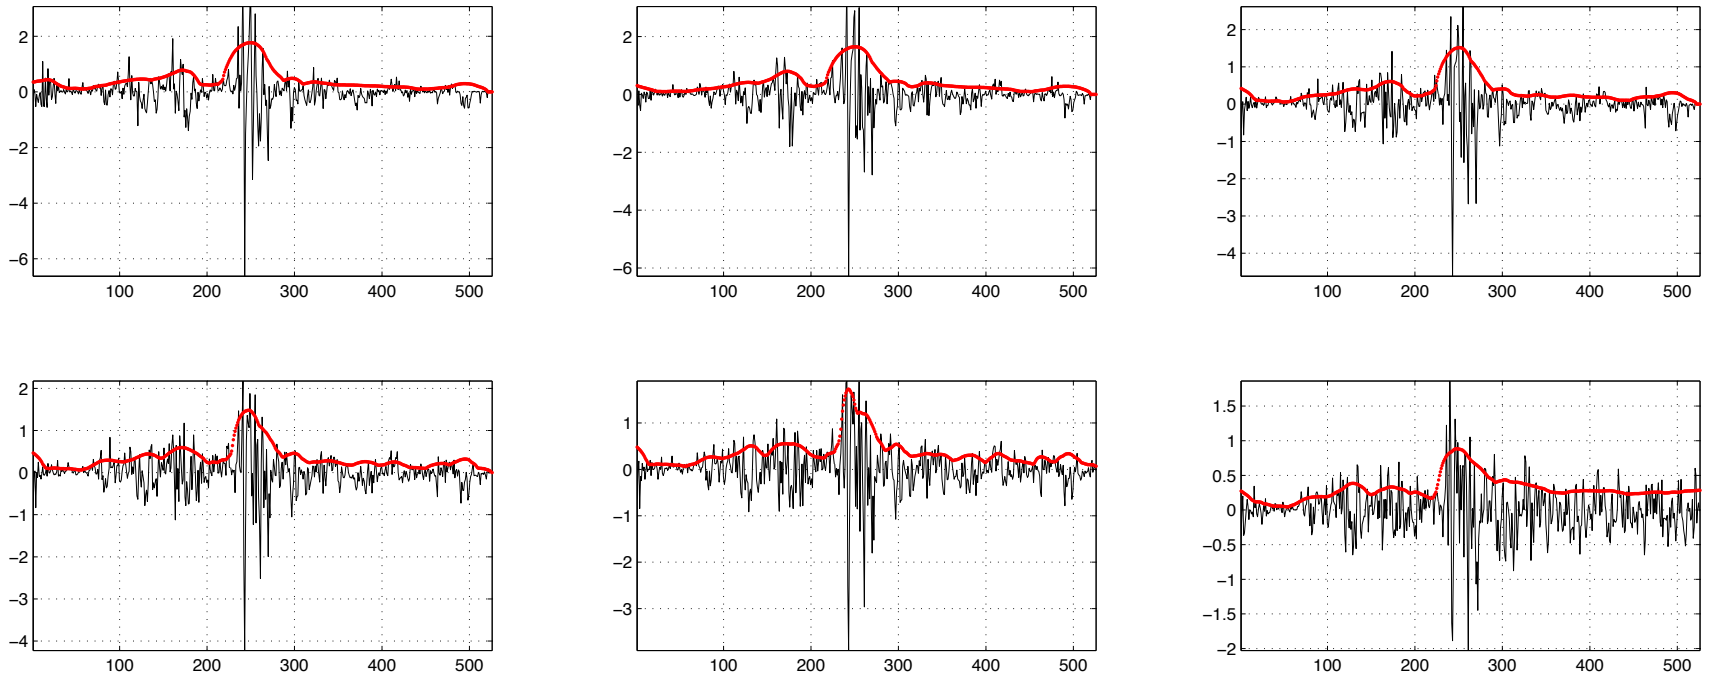


Figura: Retornos

Retornos de precios de energía a cada hora del mercado Nords Pool durante 4 años.

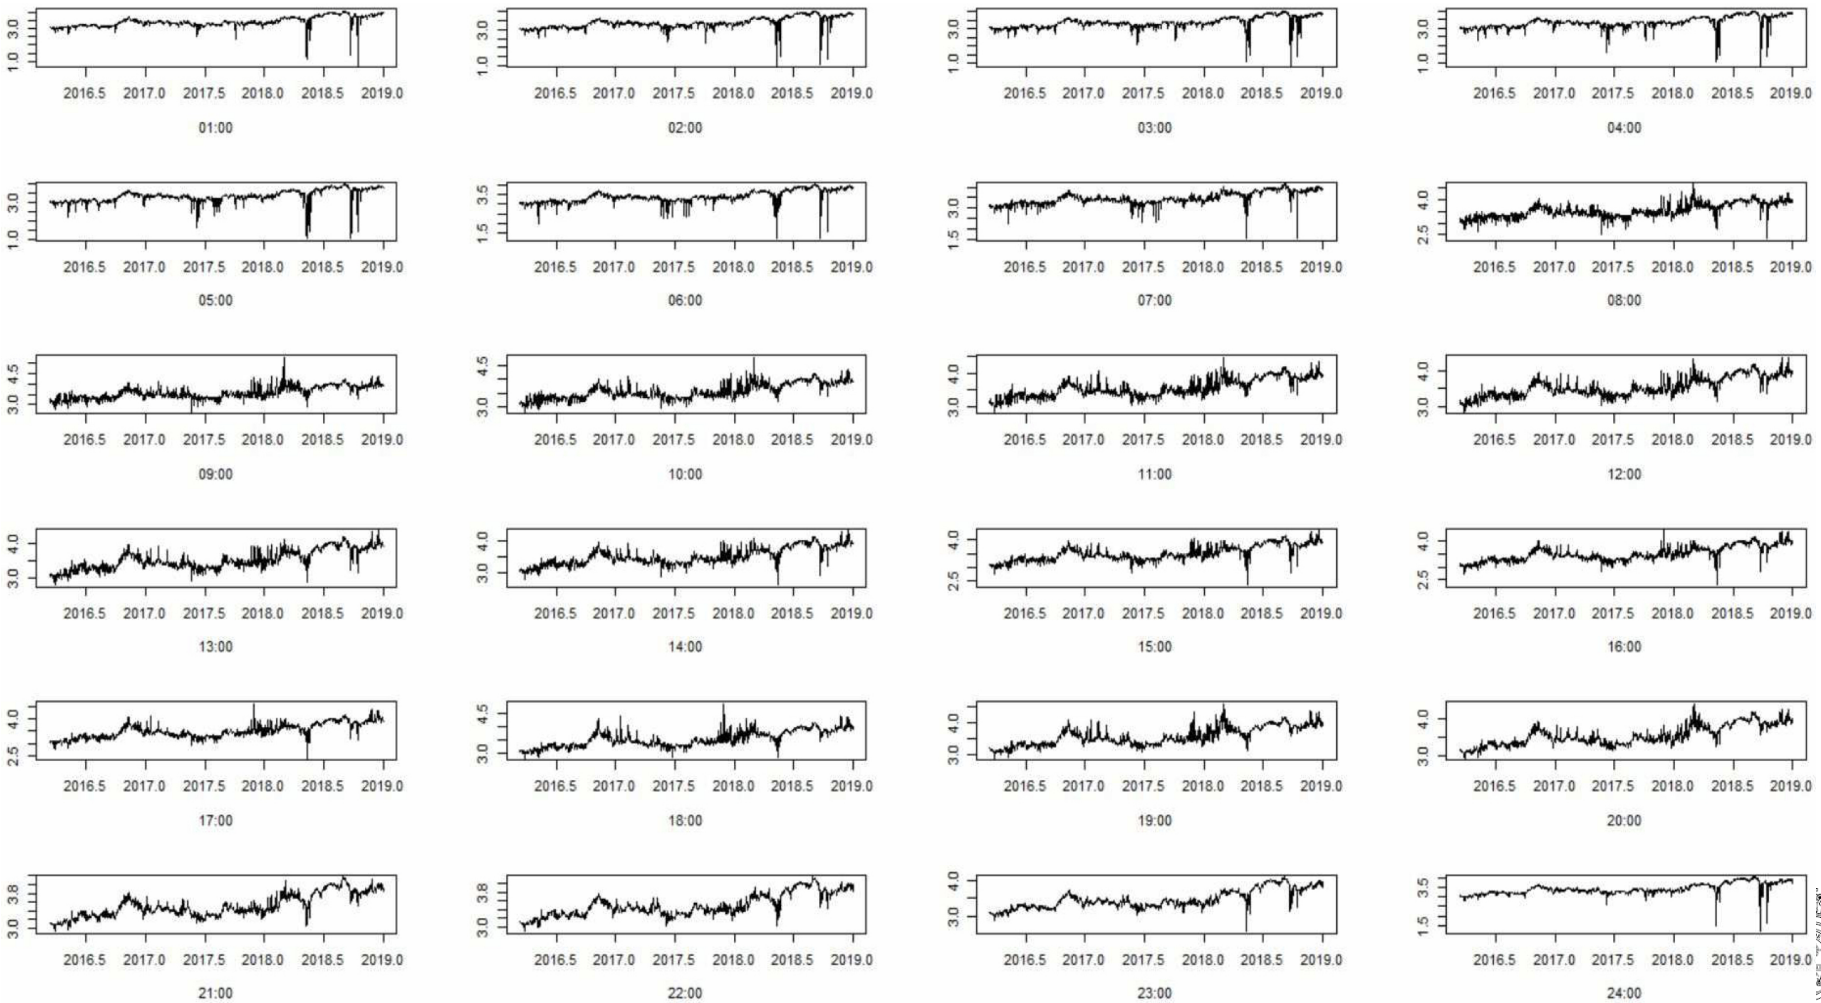
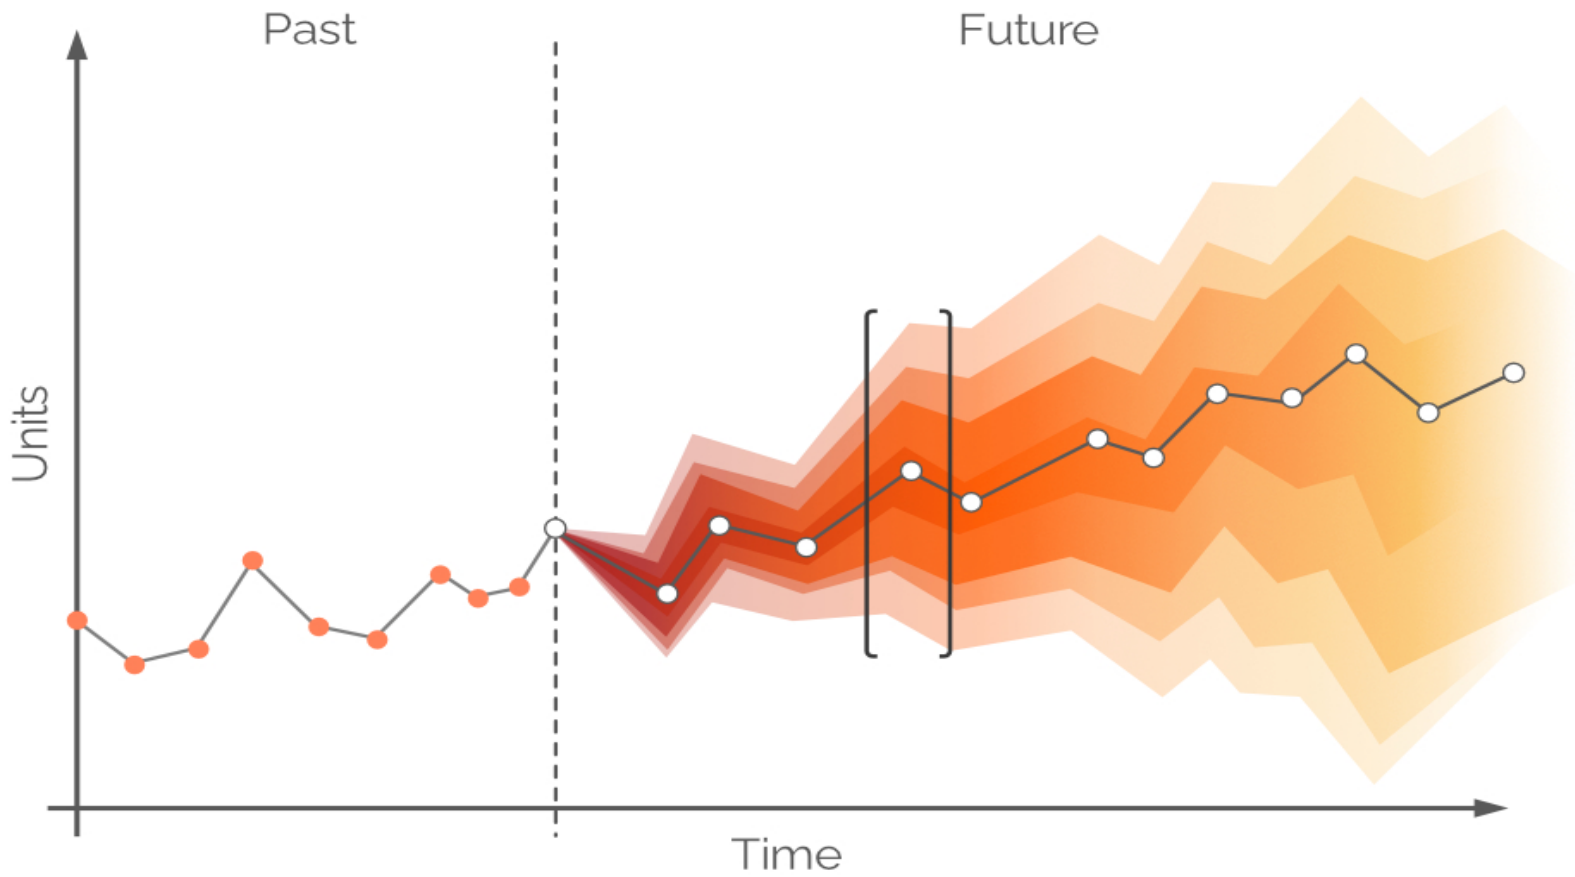


Figura: Serie Multivariada

UNIVERSIDAD DE ANTIOQUIA 1803

"La mejor forma de predecir el futuro es entender el pasado"
James Burke



UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Método de Descomposición

Dada una serie de tiempo $\{x_t\}_{t=1}^{T}$, el Modelo Aditivo consiste en asumir que x_t se puede escribir en tres componentes:

$$x_t = T_t + S_t + \epsilon_t,$$

donde T_t es la componente de tendencia, S_t componente estacional y ϵ_t la componente de errores. Las componentes T_t y S_t don funciones determinísticas de t, por tanto, su evolución es perfectamente predecible.

UNIVERSIDAD DE ANTIOQUIA
1803

Método de Descomposición

Dada una serie de tiempo $\{x_t\}_{t=1}^{T}$, el Modelo Aditivo consiste en asumir que x_t se puede escribir en tres componentes:

$$x_t = T_t + S_t + \epsilon_t,$$

donde T_t es la componente de tendencia, S_t componente estacional y ϵ_t la componente de errores. Las componentes T_t y S_t don funciones determinísticas de t, por tanto, su evolución es perfectamente predecible.

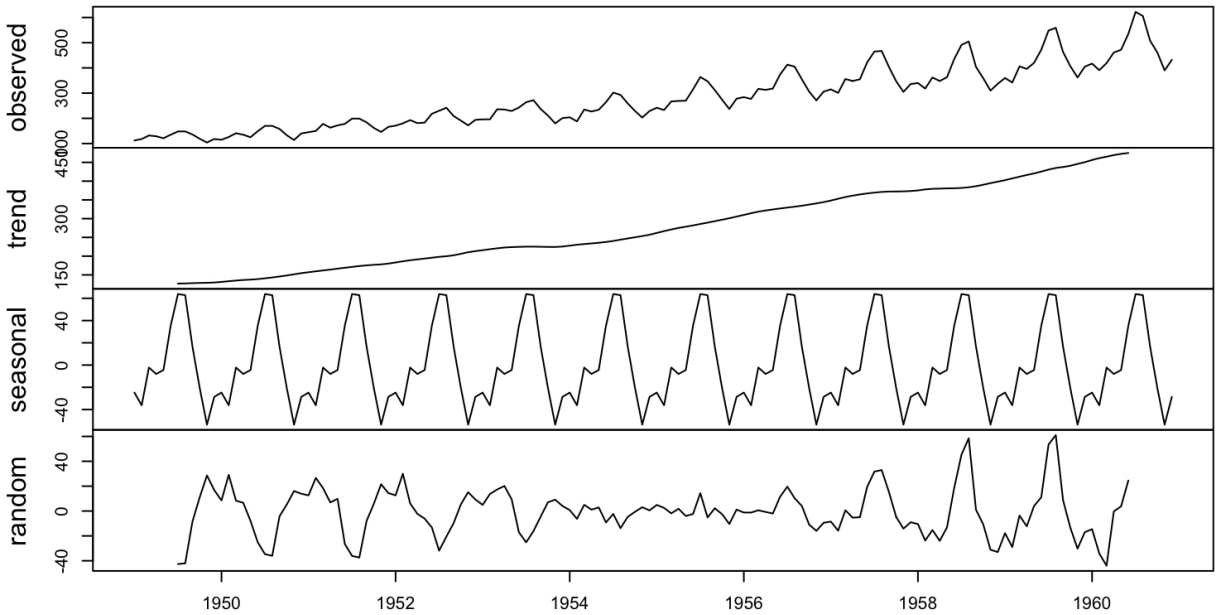


Figura: Modelo Aditivo

Método de Descomposición

El objetivo consiste en estimar T_t y S_t, con algún método (Regresión Lineal para T_t y Regresión con Frecuencias Fundamentales S_t), par obtener:

Método de Descomposición

El objetivo consiste en estimar T_t y S_t, con algún método (Regresión Lineal para T_t y Regresión con Frecuencias Fundamentales S_t), par obtener:

$$\hat{\epsilon}_t = x_t - \hat{T}_t - \hat{S}_t.$$

La serie $\hat{\epsilon}_t$, se modela para realizar el pronóstico

$$\hat{x}_{t+h} = \hat{T}_{t+h} + \hat{S}_{t+h} + \hat{\epsilon}_{t+h}, \quad \forall h > 0,$$

dada la información pasada. En particular, si $Corr(\hat{\epsilon}_t, \hat{\epsilon}_{t+s}) = 0$, para $s \neq 0$, entonces $\hat{\epsilon}_{t+h} = 0$, $\quad \forall h > 0$.

UNIVERSIDAD DE ANTIOQUIA
1803

Método de Descomposición

El objetivo consiste en estimar T_t y S_t, con algún método (Regresión Lineal para T_t y Regresión con Frecuencias Fundamentales S_t), par obtener:

$$\hat{\epsilon}_t = x_t - \hat{T}_t - \hat{S}_t.$$

La serie $\hat{\epsilon}_t$, se modela para realizar el pronóstico

$$\hat{x}_{t+h} = \hat{T}_{t+h} + \hat{S}_{t+h} + \hat{\epsilon}_{t+h}, \quad \forall h > 0,$$

dada la información pasada. En particular, si $Corr(\hat{\epsilon}_t, \hat{\epsilon}_{t+s}) = 0$, para $s \neq 0$, entonces $\hat{\epsilon}_{t+h} = 0$, $\forall h > 0$.

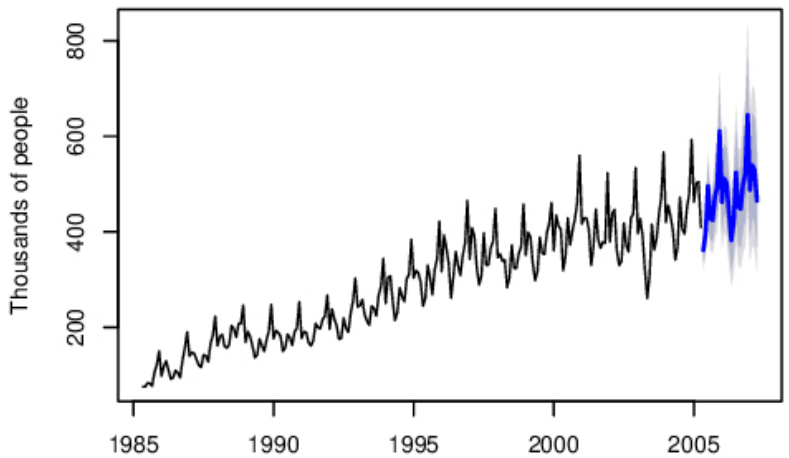


Figura: Pronóstico

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Método de Descomposición

Dada una serie de tiempo $\{x_t\}_{t=1}^{T}$, el Modelo Multiplicativo consiste en asumir que x_t se puede escribir en tres componentes:

$$x_t = T_t \cdot S_t \cdot \epsilon_t,$$

donde T_t es la componente de tendencia, S_t componente estacional y ϵ_t la componente de errores. Las componentes T_t y S_t son funciones determinísticas de t, por tanto, su evolución es perfectamente predecible.



Método de Descomposición

Dada una serie de tiempo $\{x_t\}_{t=1}^{T}$, el Modelo Multiplicativo consiste en asumir que x_t se puede escribir en tres componentes:

$$x_t = T_t \cdot S_t \cdot \epsilon_t,$$

donde T_t es la componente de tendencia, S_t componente estacional y ϵ_t la componente de errores. Las componentes T_t y S_t son funciones determinísticas de t, por tanto, su evolución es perfectamente predecible.

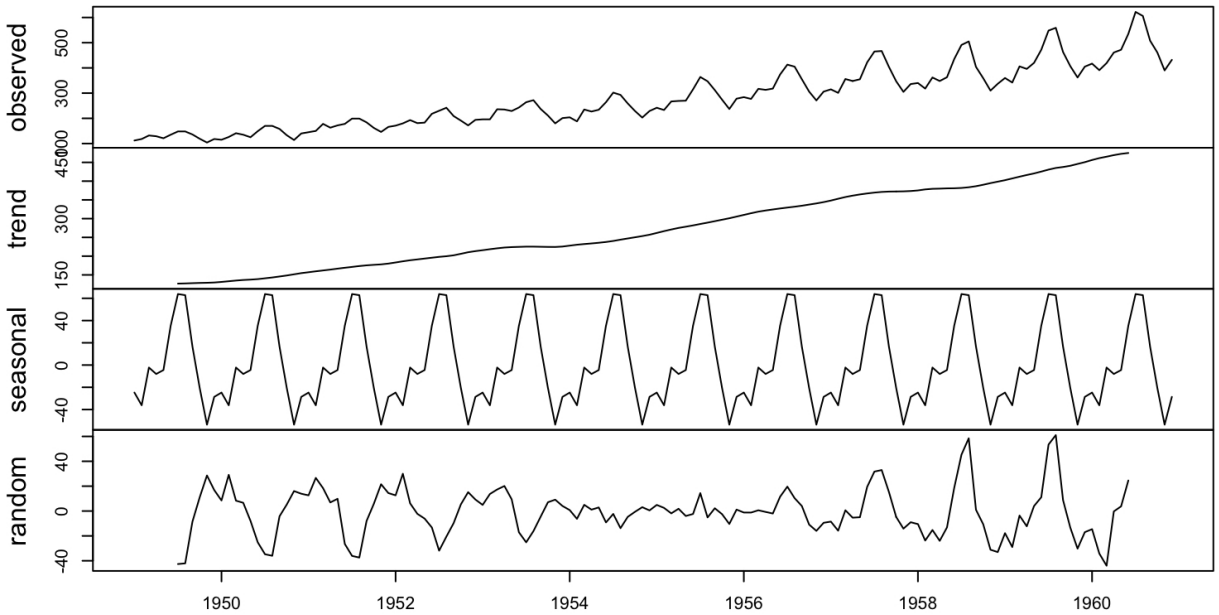


Figura: Modelo Multiplicativo

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Tendencia

Es la evolución lenta y a largo plazo de la serie x_t. Se asume que está dada por una función T_t de t, la cual es el modelo a estimar. Una definicón alternativa de Tendencia, es el cambio a largo plazo en el nivel medio de la serie.



Tendencia

Es la evolución lenta y a largo plazo de la serie x_t. Se asume que está dada por una función T_t de t, la cual es el modelo a estimar. Una definicón alternativa de Tendencia, es el cambio a largo plazo en el nivel medio de la serie.

Modelos

Existen diferentes modelos para T_t de acuerdo a sus características.

- Lineal : $T_t = \beta_0 + \beta_1 t$,

Tendencia

Es la evolución lenta y a largo plazo de la serie x_t. Se asume que está dada por una función T_t de t, la cual es el modelo a estimar. Una definicón alternativa de Tendencia, es el cambio a largo plazo en el nivel medio de la serie.

Modelos

Existen diferentes modelos para T_t de acuerdo a sus características.

- Lineal : $T_t = \beta_0 + \beta_1 t$,
- Polinomial : $T_t = \sum_{k=0}^{m} \beta_k t^k$,

Tendencia

Es la evolución lenta y a largo plazo de la serie x_t. Se asume que está dada por una función T_t de t, la cual es el modelo a estimar. Una definicón alternativa de Tendencia, es el cambio a largo plazo en el nivel medio de la serie.

Modelos

Existen diferentes modelos para T_t de acuerdo a sus características.

- Lineal : $T_t = \beta_0 + \beta_1 t$,
- Polinomial : $T_t = \sum_{k=0}^{m} \beta_k t^k$,
- Exponencial : $T_t = \exp(\beta_0 + \beta_1 t)$,

Tendencia

Es la evolución lenta y a largo plazo de la serie x_t. Se asume que está dada por una función T_t de t, la cual es el modelo a estimar. Una definicón alternativa de Tendencia, es el cambio a largo plazo en el nivel medio de la serie.

Modelos

Existen diferentes modelos para T_t de acuerdo a sus características.

- Lineal : $T_t = \beta_0 + \beta_1 t$,
- Polinomial : $T_t = \sum_{k=0}^{m} \beta_k t^k$,
- Exponencial : $T_t = \exp(\beta_0 + \beta_1 t)$,
- Logístico : $T_t = \frac{\beta_2}{1+\beta_1 \exp(-\beta_0 t)}$,

para $\beta_i \in \mathbb{R}$ e $i \in \mathbb{N}_0$.

Ejemplos de Tendencias

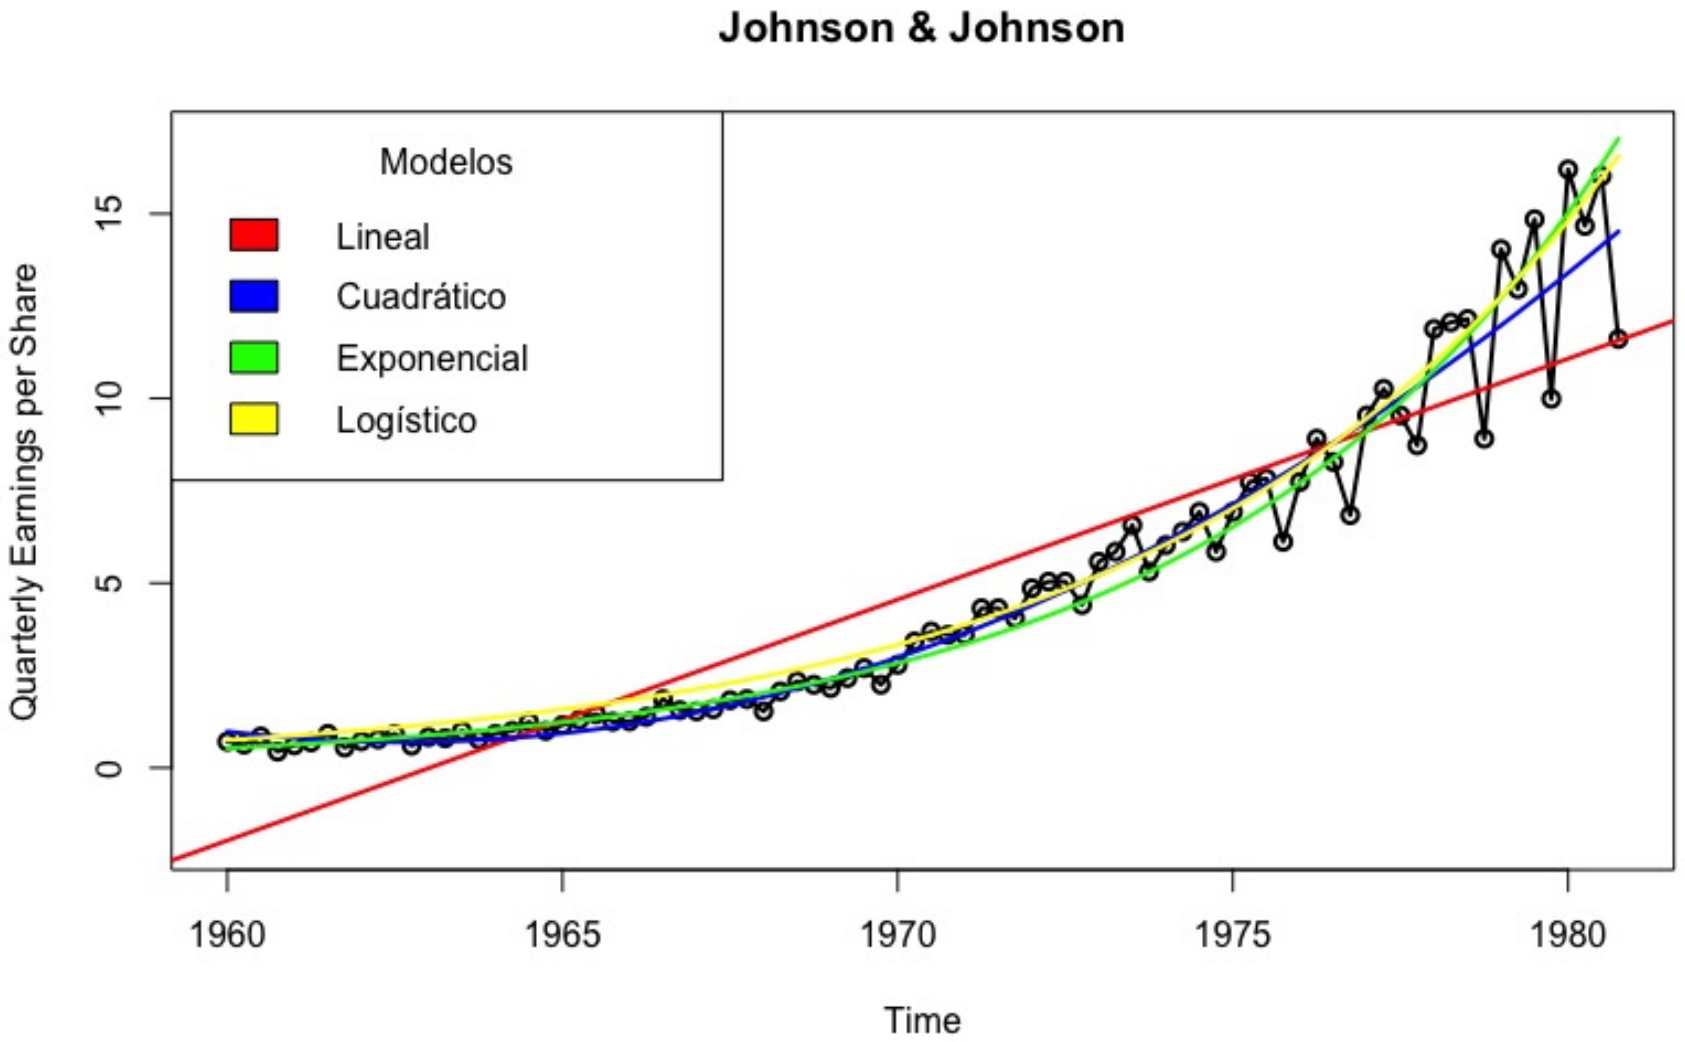


Figura: Ganacias Trimestrales de Johnson & Johnson

Para el caso de la Tendencia Polinomial, para estimar los parámetros β_j, $j = 0, 1, \ldots, m$, utilizamos el método de los Mínimos Cuadrados, minimizando la función:

Función Objetivo

$$f(\beta_0, \beta_1, \ldots, \beta_m) = \sum_{t=1}^{T} (x_t - \beta_0 - \beta_1 t - \ldots - \beta_m t^m)^2,$$

para obtener,

$$\hat{\boldsymbol{\beta}} = argmin_{\boldsymbol{\beta}} f(\boldsymbol{\beta}).$$

Para los modelos Exponencial y Logístico, es empleado Mínimos Cuadrados No Lineales, mediante el cálculo del Jacobiano por aproximación numérica.



Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Supongamos que la serie con Tendencia $x_t = T_t + \epsilon_t$, para $t = 1, 2, \ldots, T$, donde $\{\epsilon_t\}_{t=1}^{T}$ es una sucesión de variables iid con media 0 y varianza σ^2. Los pronósticos en los tiempos $T + h$, con $h \in \mathbb{N}$ (horizonte h), los definimos como:

Definición

$$\hat{x}_{T+h} = \hat{T}_{T+h}, \qquad h \in \mathbb{N}$$

Si los errores están autocorrelacionados, entonces

$$\hat{x}_{T+h} = \hat{T}_{T+h} + \hat{\epsilon}_{T+h}, \qquad h \in \mathbb{N}.$$

¿Qué hacer con los errores $\hat{\epsilon}_{t+h}$?

UNIVERSIDAD DE ANTIOQUIA 1803

Definición

El pronóstico, dada una serie $x_t, \quad t \in \mathbb{Z}$, dada la información $x_1, \ldots, x_T$ es la esperanza condicional

$$\hat{x}_{T+h} = \mathbb{E}[x_{T+h}|x_1, \ldots, x_T], \quad h \in \mathbb{N}$$

Ecuación de Pronóstico

Definición

El pronóstico, dada una serie $x_t, \quad t \in \mathbb{Z}$, dada la información $x_1, \ldots, x_T$ es la esperanza condicional

$$\hat{x}_{T+h} = \mathbb{E}[x_{T+h}|x_1, \ldots, x_T], \quad h \in \mathbb{N}$$

Nota

Para realizar un pronóstico más efectivo usando la ecuación anterior, es necesario introducir un modelo que capture la "Auto - Depedencia" de la serie temporal, lo cual estudiaremos con la metodología de ***Box*** & ***Jenkins***.

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Definición

Un Filtro Lineal es un operador que transforma una serie x_t en otra $\tilde{x}_t$ tal que

$$\tilde{x}_t = \sum_{j=-m}^{m} \omega_j x_{t-j}, \quad t = -m, \ldots, T-m,$$

donde $\omega_{-m}, \omega_{-m+1}, \ldots, \omega_0, \ldots, \omega_m$, son pesos predeterminados. Con el fin de reducir las fluctuaciones locales se restringen a $\sum_{j=-m}^{m} \omega_j = 1$.

UNIVERSIDAD DE ANTIOQUIA
1803

Definición

Para pesos simétricos $\omega_j = \omega_{-j}$, para $j = 0, 1, \ldots, m$, se tiene que

$$\tilde{x}_t = \sum_{j=-m}^{m} \omega_j x_{t-j}.$$

- Si $j > 0$, x_{t-j} se denomina rezago de orden j.
- Si $j < 0$, x_{t-j} se denomina valor futuro.

En particular, si los pesos son $\omega_j \sim N(0, 1)$, se denominan pesos gaussianos.

UNIVERSIDAD DE ANTIOQUIA
1803

Definición

Para este caso seleccionamos los pesos con los siguientes valores:

$$\omega_j = \frac{1}{2m+1}, \quad para \quad j = -m, \ldots, m.$$

Gráficamente se trata de calcular promedios en ventanas de longitud $(2m+1)$, dando un peso mayor al datos central de la ventana.

UNIVERSIDAD DE ANTIOQUIA
1803

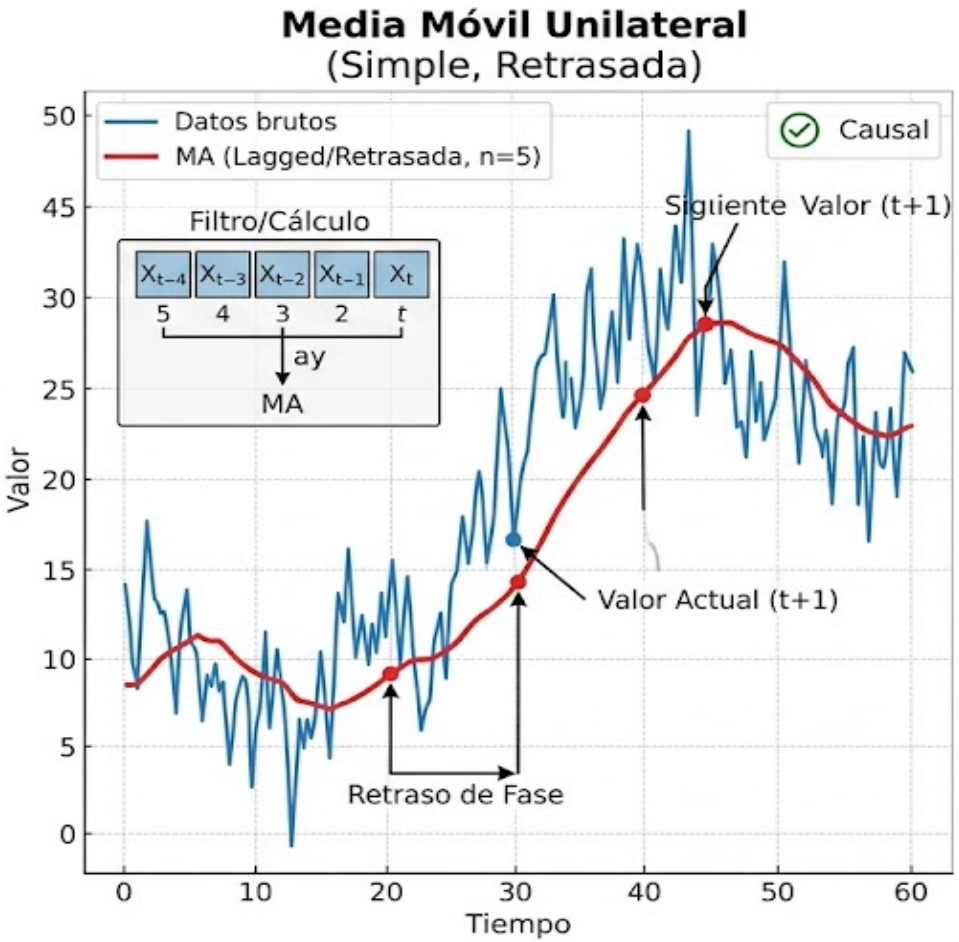
Definición

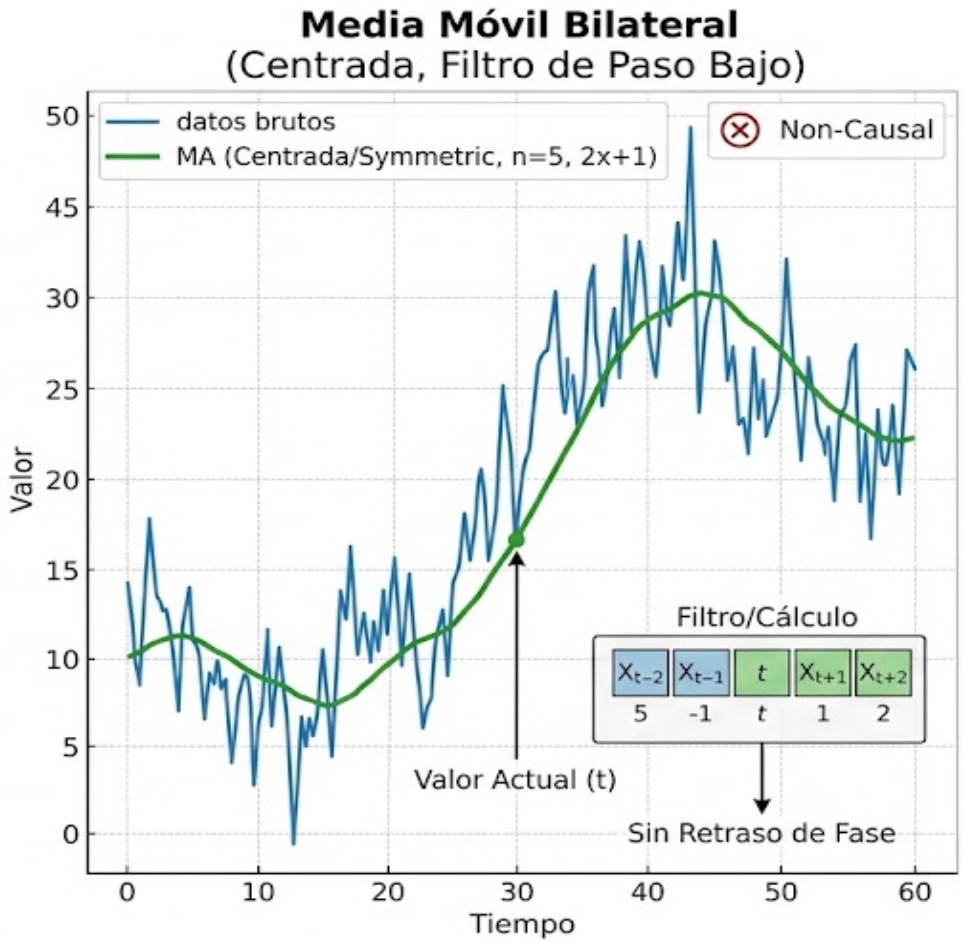
Para este caso seleccionamos los pesos con los siguientes valores:

$$\omega_j = \frac{1}{m+1}, \quad para \quad j = 0, 1, \ldots, m.$$

El entero $m \geq 1$, se denomina "Ancho de Ventana de la Media Móvil". Esta Media Móvil solo emplea valores pasados y presentes de la serie, es decir, se trata de un filtro lineal causal, mientras que la Bilateral no lo es.

Ilustración Media Móvil Unilateral y Bilateral





UNIVERSIDAD DE ANTIOQUIA
1803

Ejemplo - Media Móvil Unilateral $m = 3$

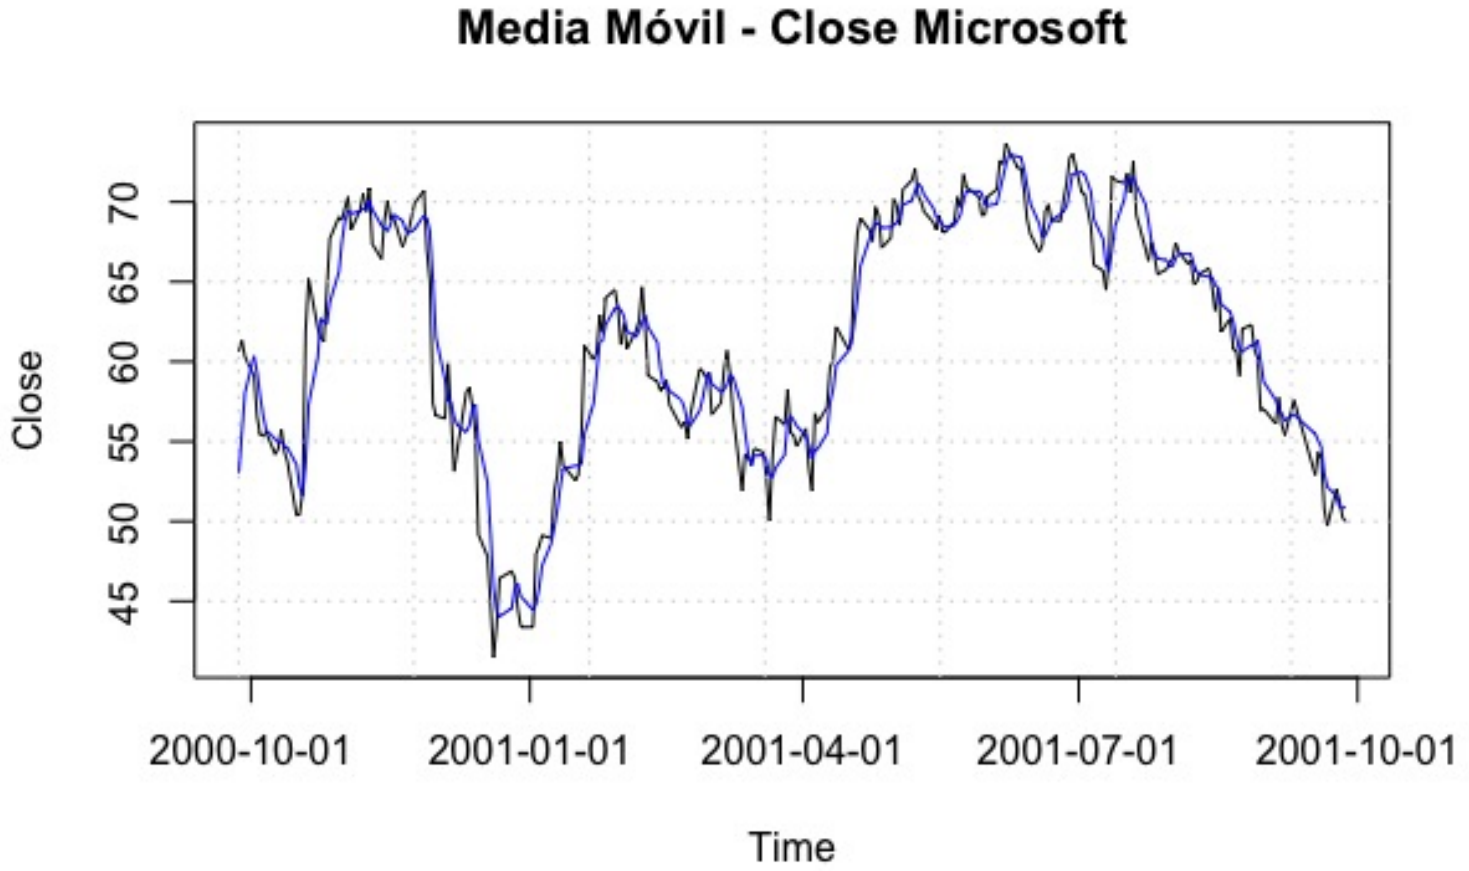


Figura: Close Microsoft

UNIVERSIDAD DE ANTIOQUIA
1803

Ejemplo - Media Móvil Unilateral $m = 13$

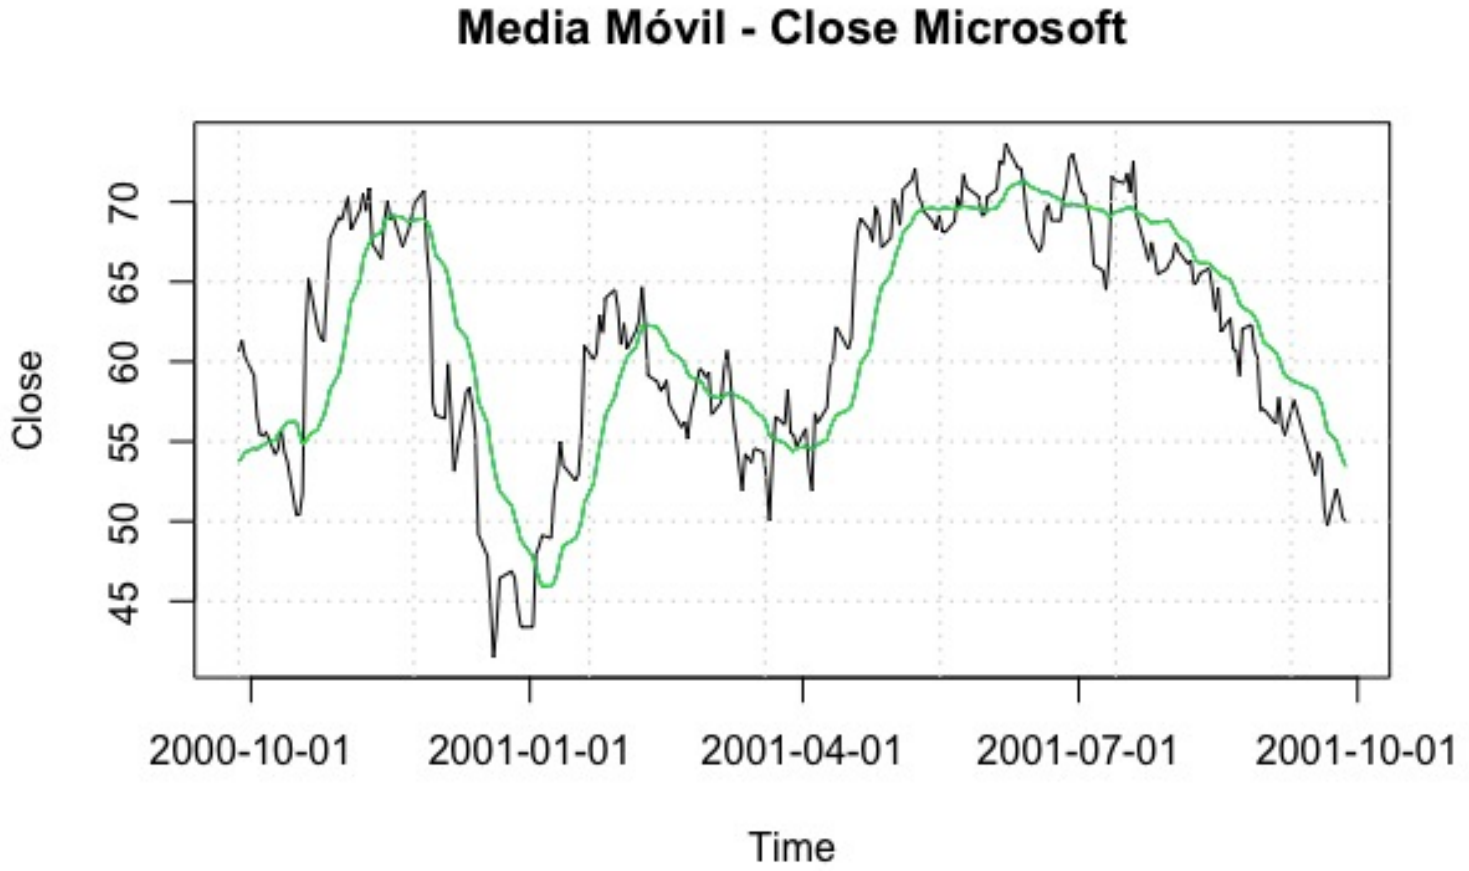


Figura: Close Microsoft

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Suavización Exponencial Simple (S.E.S)

Pondera todos los datos pasados con ponderaciones que disminuyen exponencialmente al ir hacia el pasado. Es decir, normalmente los datos más reciente tienen una mayor ponderación. La ponderación de esta forma supera en gran medida las limitaciones de promedios móviles o métodos de cambio de porcentaje.

Este método, cuyo resultado es una previsión plana, recta, es el mejor para datos volátiles sin tendencia ni estacionalidad.

UNIVERSIDAD DE ANTIOQUIA
1803

Suavización Exponencial Simple (S.E.S)

Pondera todos los datos pasados con ponderaciones que disminuyen exponencialmente al ir hacia el pasado. Es decir, normalmente los datos más reciente tienen una mayor ponderación. La ponderación de esta forma supera en gran medida las limitaciones de promedios móviles o métodos de cambio de porcentaje.

Este método, cuyo resultado es una previsión plana, recta, es el mejor para datos volátiles sin tendencia ni estacionalidad.

S.E.S

$$\tilde{x}_t = \alpha x_{t-1} + (1-\alpha)\tilde{x}_{t-1}, \quad t \in \mathbb{N},$$

donde $\tilde{x}_t$ es denominado valor exponencialmente suavizado y $\alpha \in (0,1)$.

UNIVERSIDAD DE ANTIOQUIA
1803

La constante funciona como un factor de ponderación y su variación se hace de acuerdo a nuestra necesidad de darle más peso a datos recientes (α más elevado) o a datos pasados (α más bajo). Si $\alpha = 1$, nuestro pronóstico del próximo periodo será exactamente igual al del periodo actual.

Expresión Recursiva

$$\tilde{x}_t = \sum_{k=0}^{t-1} \alpha(1-\alpha)^k x_{t-k-1} + (1-\alpha)^t \tilde{x}_0, \quad t = 1, 2, \ldots, T.$$

La constante funciona como un factor de ponderación y su variación se hace de acuerdo a nuestra necesidad de darle más peso a datos recientes (α más elevado) o a datos pasados (α más bajo). Si $\alpha = 1$, nuestro pronóstico del próximo periodo será exactamente igual al del periodo actual.

Expresión Recursiva

$$\tilde{x}_t = \sum_{k=0}^{t-1} \alpha(1-\alpha)^k x_{t-k-1} + (1-\alpha)^t \tilde{x}_0, \quad t = 1, 2, \ldots, T.$$

Notemos que los pesos

$$f(z) = \alpha(1-\alpha)^z,$$

para $\alpha \in (0,1)$ y $z \in \mathbb{R}^+$, es decreciente como función de z.

Interpretación de α

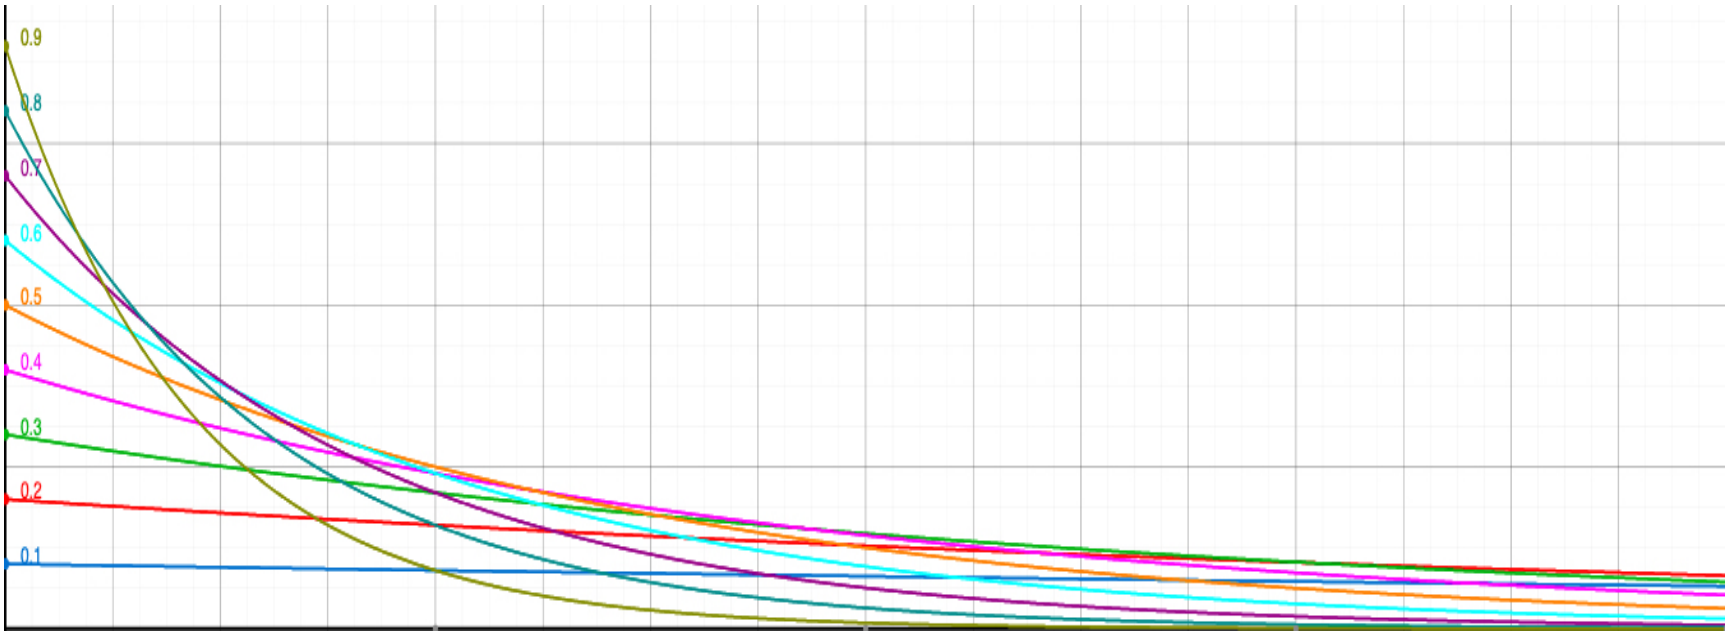


Figura: Función de Ponderación Exponencial

UNIVERSIDAD DE ANTIOQUIA
1803

La predicción de todos las valores futuros para la series de tiempo $x_1, x_2, \ldots, x_T$, es dada por la siguiente relación:

Ecuación de Pronóstico

$$\hat{x}_T(h) = \tilde{x}_{T+h}, \quad \forall h > 0.$$

La predicción de todos las valores futuros para la series de tiempo $x_1, x_2, \ldots, x_T$, es dada por la siguiente relación:

Ecuación de Pronóstico

$$\hat{x}_T(h) = \tilde{x}_{T+h}, \quad \forall h > 0.$$

Puede ser interpretada como una ecuación de actualización de predicción, cuando tenemos una nueva observación.



Ejercicios

Para el caso de la Suavización Exponencial Simple (S.E.S), definida en la expresión recursiva anterior, probar los siguientes resultados.

- Suponga que la serie de tiempo $x_1, x_2, \ldots, x_T$, es una realización de un proceso estocástico tal que $\mathbb{E}[x_t] = \mu, \quad \forall t \in \mathbb{N}$. Demostrar que $\mathbb{E}[\tilde{x}_t] = \mu$, para t sufientemente grande.

- Bajo las condiciones anteriores y asumiendo que $\mathbb{V}ar[x_t] = \sigma^2$, demostrar que

$$\mathbb{V}ar[\tilde{x}_t] = \frac{\alpha}{2-\alpha}\sigma^2,$$

  para t suficientemente grande. ¿ Hay que asumir no correlación?

- Con la información de los items anteriores, construir un Intervalo de Confianza Asintótico del 95 %, para $\hat{x}_T(h)$, con $h \in \mathbb{N}$.

UNIVERSIDAD DE ANTIOQUIA
1803

Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Modelo de Holt-Winters

- El modelo de Holt-Winters es una técnica de análisis de series de tiempo que predice valores futuros a partir de patrones históricos, la cual es una mejora del método de Suavización Exponencial.



Modelo de Holt-Winters

- El modelo de Holt-Winters es una técnica de análisis de series de tiempo que predice valores futuros a partir de patrones históricos, la cual es una mejora del método de Suavización Exponencial.

- Se basa en un algoritmo iterativo que realiza pronósticos sobre el comportamiento de una serie de tiempo y de promedios ponderados de datos anteriores.

Modelo de Holt-Winters

- El modelo de Holt-Winters es una técnica de análisis de series de tiempo que predice valores futuros a partir de patrones históricos, la cual es una mejora del método de Suavización Exponencial.

- Se basa en un algoritmo iterativo que realiza pronósticos sobre el comportamiento de una serie de tiempo y de promedios ponderados de datos anteriores.

Modelo de Holt-Winters

- El modelo de Holt-Winters es una técnica de análisis de series de tiempo que predice valores futuros a partir de patrones históricos, la cual es una mejora del método de Suavización Exponencial.

- Se basa en un algoritmo iterativo que realiza pronósticos sobre el comportamiento de una serie de tiempo y de promedios ponderados de datos anteriores.

Definición

El modelo de Holt-Winters es un algoritmo para estimar recursivamente las cantidades

$$\mu_t = \beta_{0,t},$$

$$\beta_t = \beta_{1,t} t,$$

$$S_t = \sum_{j=1}^{s} \delta_{j,t} I_j(t),$$

a partir de unos valores iniciales $\mu_{0,0}$, $S_{0,j} = \delta_{j,0}$, para $j = 1, 2, \ldots, s$.

Fue introducido por Winters [1960].

UNIVERSIDAD DE ANTIOQUIA
1803

Definición

El algoritmo Holt-Winters consiste en el sistema de ecuaciones recursivas para μ_t, β_t y S_t, dado por

$$\mu_t = \alpha(X_t - S_{t-s}) + (1-\alpha)(\mu_{t-1} + \beta_{t-1}),$$

$$\beta_t = \beta(\mu_t - \mu_{t-1}) + (1-\beta)\beta_{t-1},$$

$$S_t = \gamma(X_t - \mu_t) + (1-\gamma)S_{t-s},$$

para $t = 2, \ldots, T$ y $\alpha, \beta, \gamma \in (0,1)$ son los parámetros de suavizamiento y se escogen de manera que se minimize el MSE.



Definición

El algoritmo Holt-Winters consiste en el sistema de ecuaciones recursivas para μ_t, β_t y S_t, dado por

$$\mu_t = \alpha(X_t - S_{t-s}) + (1-\alpha)(\mu_{t-1} + \beta_{t-1}),$$

$$\beta_t = \beta(\mu_t - \mu_{t-1}) + (1-\beta)\beta_{t-1},$$

$$S_t = \gamma(X_t - \mu_t) + (1-\gamma)S_{t-s},$$

para $t = 2, \ldots, T$ y $\alpha, \beta, \gamma \in (0,1)$ son los parámetros de suavizamiento y se escogen de manera que se minimize el MSE.

La programación en `R` o `Python` del método **Holt-Winters** se puede hacer de manera que se estiman las constantes α, β, y γ automáticamente, como los valores que minimizan el MSE. Alternativamente, se puede ingresar un valor particular para cada constante.



Contenido

1. Introducción
2. Descomposición Aditiva: $x_t = T_t + S_t + \epsilon_t$
3. Descomposición Multiplicativa: $x_t = T_t S_t \epsilon_t$
4. Modelos y Estimación para T_t
5. Pronósticos Basados en T_t
6. Filtros Lineales y Medias Móviles
7. Suavización Exponencial Simple (S.E.S)
8. Modelo de Holt-Winters
9. Referencias

UNIVERSIDAD DE ANTIOQUIA
1803

Referencias

Norman Giraldo Gómez (2006)
Técnica de Pronósticos. Aplicaciones en R.
Notas de Clase.

Pedro A. Morettin e Clélia M. C. Toloi (2004)
Análise de Séries Temporais.
BLUCHER, São Paulo, Brasil.

https://github.com/duvancatan/Data_Time_Series_UdeA/blob/main/notebooks/1_Tendencia_Suavizacion_R.ipynb

UNIVERSIDAD DE ANTIOQUIA
1803